Procesamiento de Lenguaje Natural I

Vectorización de texto

Docentes:
MSc. Fernando Silva
MSc. Josselyn Ordoñez

emails: fernandosilva.clases2@gmail.com
josselynsofia@gmail.com

Programa del curso

Clase 1: Introducción a NLP, Vectorización de documentos.
Clase 2: Word embeddings.
Clase 3: Redes recurrentes: Elman, LSTM y GRU.
Clase 4: Modelos de lenguaje y generación de secuencias.
Clase 5: CNNs, introducción a atención. Modelos de clasificación.
Clase 6: Modelos Seq2seq.
Clase 7: Mecanismo de atención, Transformers.
Clase 8: Grandes modelos de lenguaje.

*Unidades con desafíos de código a presentar al finalizar el curso.

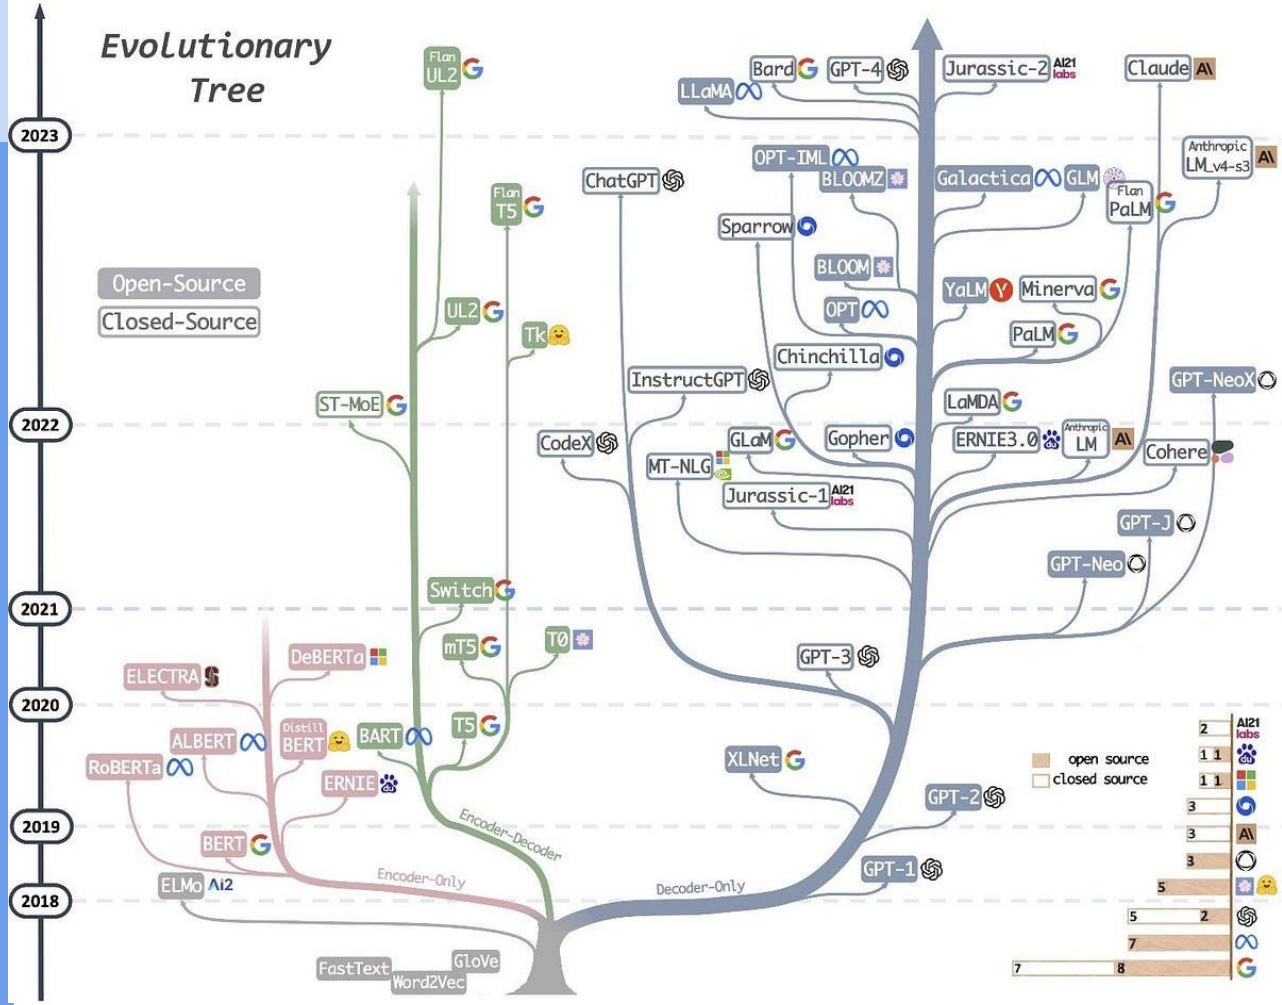
Evolutionary Tree
Open-Source
Closed-Source
2023
2022
2021
2020
2019
2018
Flan UL2
Flan T5
UL2
Tk
ST-MoE
Switch
mT5
T0
T5
ELECTRA
DeBERTa
ALBERT
Distill BERT
BART
RoBERTa
ERNIE
BERT
ELMo
FastText
GloVe
Word2Vec
Encoder-Only
Encoder-Decoder
Decoder-Only
LLaMA
Bard
GPT-4
Jurassic-2
Claude
OPT-IML
BLOOMZ
ChatGPT
Galactica
GLM
Flan PaLM
Anthropic LM_v4-s3
Sparrow
BLOOM
OPT
YaLM
Minerva
PaLM
Chinchilla
InstructGPT
GPT-NeoX
LaMDA
CodeX
GLaM
Gopher
ERNIE3.0
Anthropic LM
Cohere
MT-NLG
Jurassic-1
GPT-J
GPT-Neo
GPT-3
XLNet
GPT-2
GPT-1
open source
closed source

Link Github de la materia

https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/procesamiento_lenguaje_natural

Desafíos propuestos

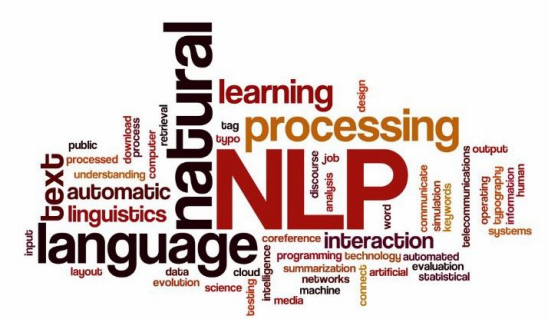

Vectorización de texto

Word embeddings

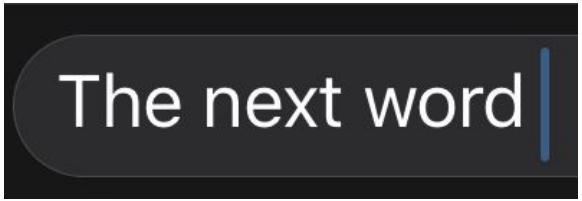

Generación de secuencias

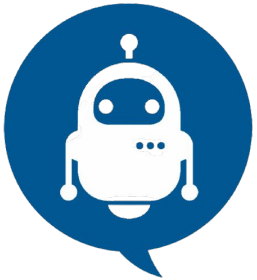

Modelos seq2seq

¿Cómo se entregan las resoluciones?

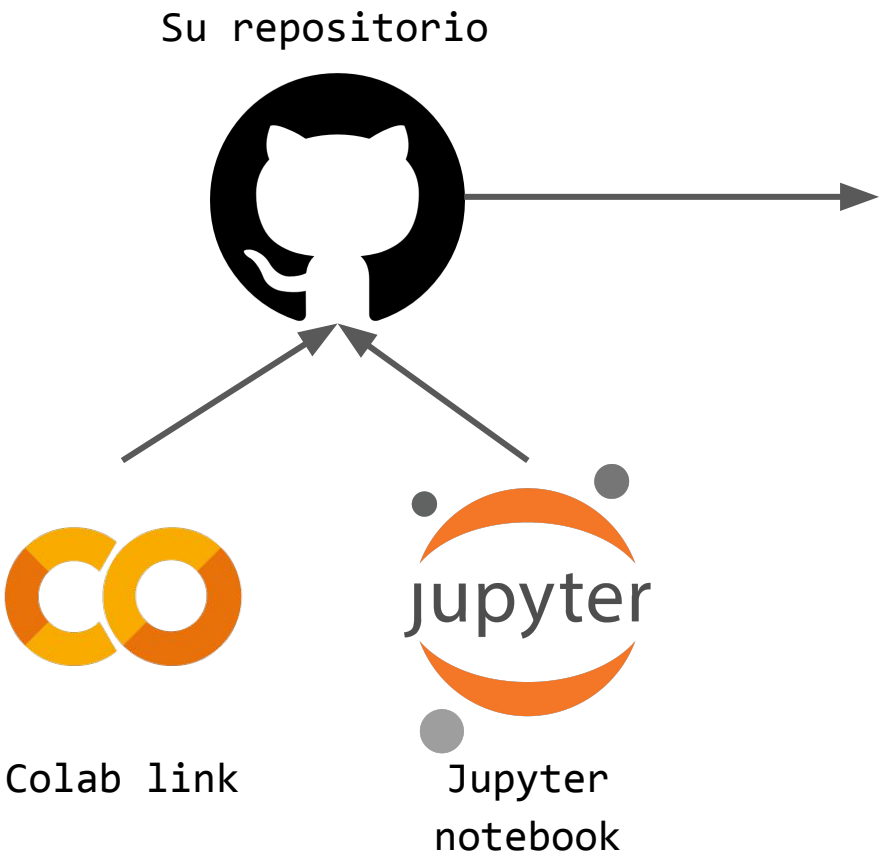

Envían por mail el link del repositorio notificando que ya podemos observar su trabajo NºX

¿Cómo se evaluarán los desafíos?

Nota máxima si la primera entrega se hace hasta última hora de Argentina del jueves de la clase…

	1	2	3	4	5	6	7	8	cierre de notas
Desafío 1	**10**	**10**	**10**	**9**	**9**	**8**	**7**	**6**	**5**
Desafío 2		**10**	**10**	**10**	**9**	**9**	**8**	**7**	**6**
Desafío 3				**10**	**10**	**10**	**9**	**8**	**7**
Desafío 4						**10**	**10**	**10**	**9**

Los desafíos son individuales y deben ser subidos a un repositorio personal.

PARA APROBAR EL CURSO TODOS LOS DESAFÍOS DEBEN SER ENTREGADOS Y EVALUADOS SATISFACTORIAMENTE ANTES DE LA FECHA DEL CIERRE DE NOTAS

Descansos

Opción A:

Primera Parte	Descanso (10 min)	Segunda Parte	Descanso (10 min)	Tercera Parte

Opción B:

Primera Parte	Descanso (20 min)	Segunda Parte

Agenda

- Introducción al Procesamiento de Lenguaje Natural (NLP)
- Historia del NLP
- Aplicaciones de NLP
- Tareas de NLP
- Preprocesamiento de Texto
- Vectorización de Texto
- Machine Learning para NLP

Introducción al Procesamiento de Lenguaje Natural (NLP)

¿Qué es el lenguaje?

Desde un punto de vista de la **Lingüística**:

- El Lenguaje es un sistema de símbolos más reglas. Contempla semántica, sintaxis, y es pragmática.

- Chomsky menciona la idea de gramática generativa:
  - Donde tenemos un conjunto de reglas capaces de generar todas las oraciones correctas de un idioma.
  - Con pocas reglas podemos generar infinitas oraciones.
  - **En NLP clásico se intentó modelar lenguaje con reglas tipo Chomsky.**

¿Qué es el lenguaje?

Desde un punto de vista de la **Lingüística**:

- El Lenguaje es un sistema de símbolos más reglas. Contempla semántica, sintaxis, y es pragmática.

- ¿Los Large Language Models (LLMs) conocen gramática o solo patrones?
  - ¿son loros estocásticos? (**Clase 7 y 8**)

On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? 🦜

Emily M. Bender*
ebender@uw.edu
University of Washington
Seattle, WA, USA

Timnit Gebru*
timnit@blackinai.org
Black in AI
Palo Alto, CA, USA

Angelina McMillan-Major
aymm@uw.edu
University of Washington
Seattle, WA, USA

Shmargaret Shmitchell
shmargaret.shmitchell@gmail.com
The Aether

On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? (2021)

¿Qué es el lenguaje?

Desde un punto de vista de la **Filosofía**:

- Ludwig Wittgenstein propone una idea clave:

  "El significado de una palabra es su uso en el lenguaje."

- Esto rompe con la idea clásica de que las palabras tienen significado fijo.

- Por ejemplo la palabra "banco" puede significar:
  - Banco financiero
  - Banco para sentarse
  - Banco de peces

  El significado depende del contexto.

¿Qué es el lenguaje?

Desde un punto de vista de la **Filosofía**:

- Ludwig Wittgenstein propone una idea clave:

"El significado de una palabra es su uso en el lenguaje."

- Esta idea está muy relacionada a un concepto llamado **embeddings** (**Clase 2**):

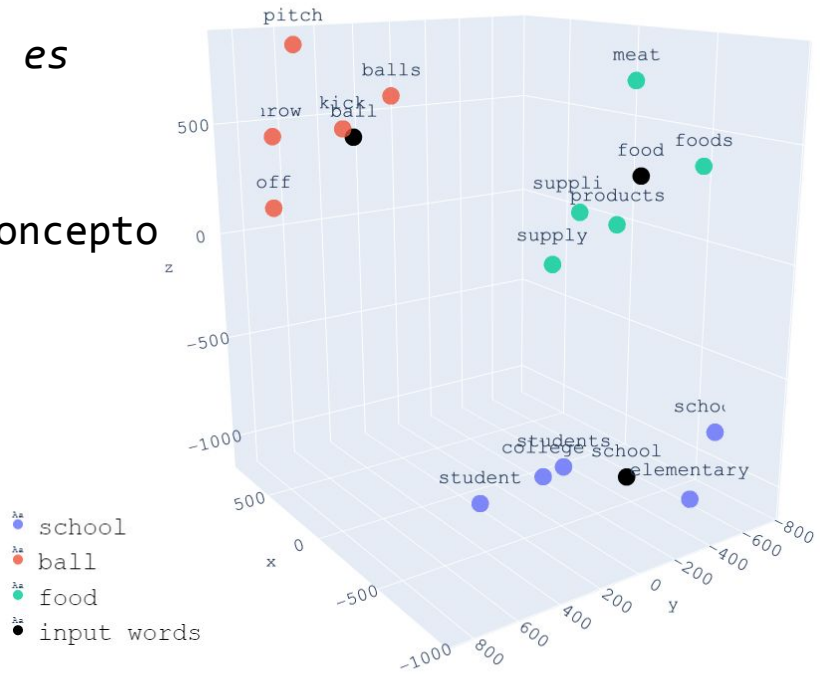

¿Qué es el Procesamiento de Lenguaje Natural?

El procesamiento de lenguaje natural (PLN o NLP) es el área de la Inteligencia Artificial que desarrolla modelos computacionales capaces de representar, procesar, comprender y generar lenguaje humano mediante métodos algorítmicos y estadísticos.

Desde IA, NLP implica cuatro cosas clave:

1.- Representación: Transformar lenguaje (texto o voz) en estructuras matemáticas

2.- Modelado: Construir funciones que capturen regularidades del lenguaje.

3.- Inferencia: Dado un input lingüístico, producir una salida coherente.

4.- Aprendizaje: Ajustar parámetros a partir de datos textuales masivos.

Manifestaciones del Lenguaje

Lenguaje hablado
En NLP: Speech Processing

Lenguaje escrito
En NLP: Desde N-Grams hasta **Transformers**

Lenguaje gestual
En NLP: Desde Sign Language Recognition hasta **MultiModalidad**

Lenguaje digital
En NLP: Desde Sentiment analysis hasta **Topic modeling**

Historia del NLP

Test de turing (1950)

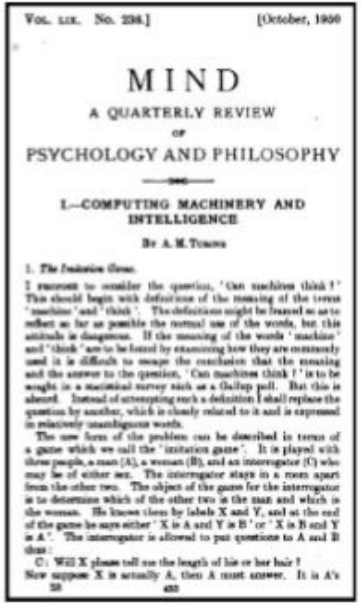

Vol. LIX. No. 236.] [October, 1950

MIND

A QUARTERLY REVIEW

OF

PSYCHOLOGY AND PHILOSOPHY

I.—COMPUTING MACHINERY AND INTELLIGENCE

By A. M. Turing

1. *The Imitation Game.*

I propose to consider the question, 'Can machines think?' This should begin with definitions of the meaning of the terms 'machine' and 'think'. The definitions might be framed so as to reflect so far as possible the normal use of the words, but this attitude is dangerous. If the meaning of the words 'machine' and 'think' are to be found by examining how they are commonly used it is difficult to escape the conclusion that the meaning and the answer to the question, 'Can machines think?' is to be sought in a statistical survey such as a Gallup poll. But this is absurd. Instead of attempting such a definition I shall replace the question by another, which is closely related to it and is expressed in relatively unambiguous words.

The new form of the problem can be described in terms of a game which we call the 'imitation game'. It is played with three people, a man (A), a woman (B), and an interrogator (C) who may be of either sex. The interrogator stays in a room apart from the other two. The object of the game for the interrogator is to determine which of the other two is the man and which is the woman. He knows them by labels X and Y, and at the end of the game he says either 'X is A and Y is B' or 'X is B and Y is A'. The interrogator is allowed to put questions to A and B thus:

C: Will X please tell me the length of his or her hair?

Now suppose X is actually A, then A must answer. It is A's

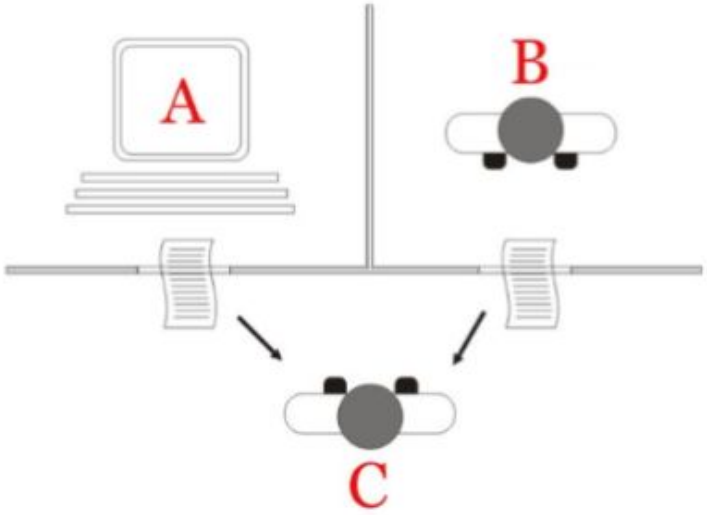

¿Puede una máquina hablar como si fuera un humano?

Eliza (1964) - Primer bot NLP

```
 Welcome to
                    EEEEEE  LL      IIII  ZZZZZZZ   AAAAA
                    EE      LL       II       ZZ   AA   AA
                    EEEEE   LL       II     ZZZ    AAAAAAA
                    EE      LL       II    ZZ      AA   AA
                    EEEEEE  LLLLLL  IIII  ZZZZZZZ  AA   AA

 Eliza is a mock Rogerian psychotherapist.
 The original program was described by Joseph Weizenbaum in 1966.
 This implementation by Norbert Landsteiner 2005.


ELIZA: Please tell me what's been bothering you.
YOU:   I don't really know
ELIZA: Do you wish to be able to really know ?
YOU:   Hmm.. well, I guess yes
ELIZA: Do you say you guess yes for some special reason ?
YOU:   I don't really know
ELIZA: Does that trouble you ?
YOU:   What do you think?
ELIZA: What are your feelings now ?
YOU:   Sad
ELIZA: Does talking about this bother you ?
YOU:
```

Se basaba en encontrar las palabras claves del texto y utilizarlas para formular una pregunta

Statistical Machine Translation (1990)

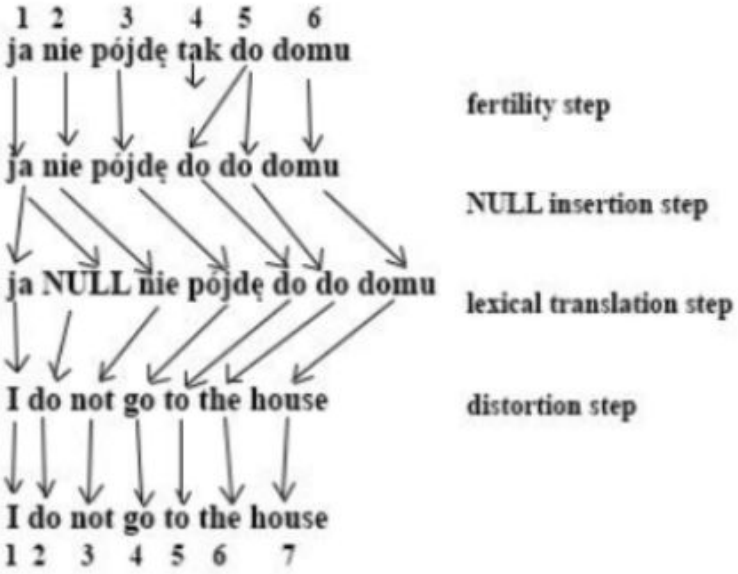

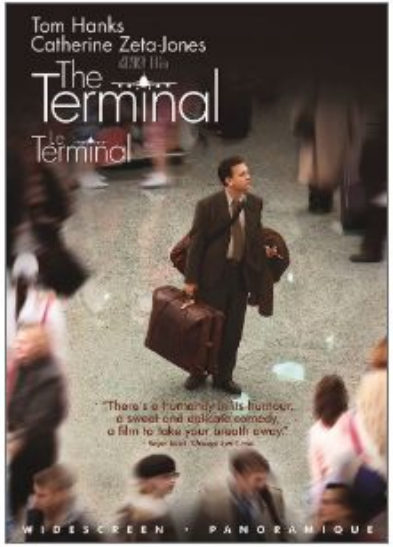

IBM introduce los SMT. Los cuales se basan en probabilidad para traducir texto de un idioma a otro.

Estos modelos son conocidos por su enfoque de alineación de palabras y su uso de datos paralelos para aprender traducciones.

Deep Learning (2012 - ...)

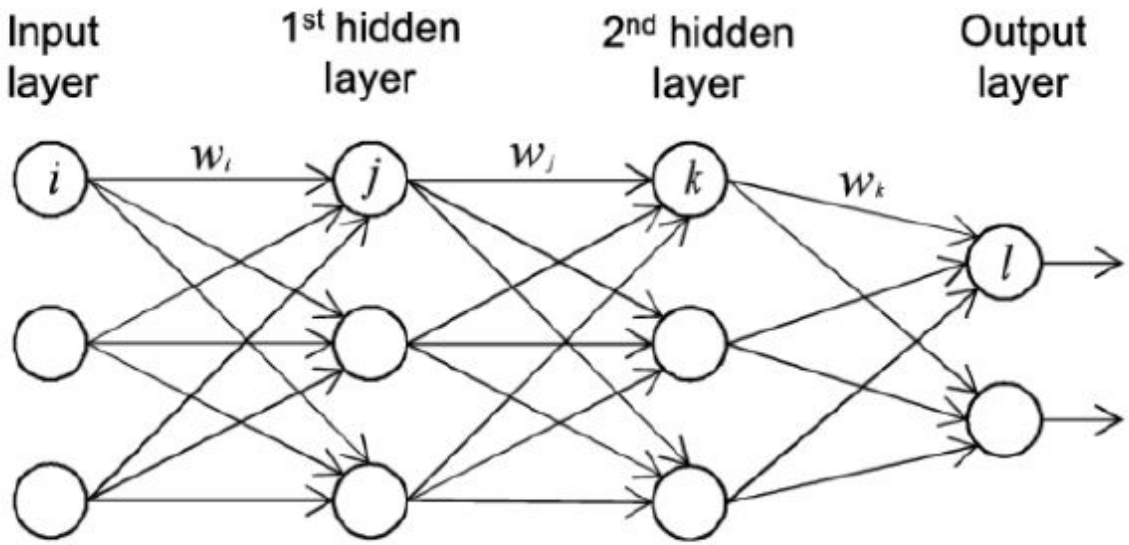

$$y_j = f\left(\sum x_i w_i\right) \quad y_k = f\left(\sum x_j w_j\right) \quad y_l = f\left(\sum x_k w_k\right)$$

Reduce esfuerzos manuales.

Tres ingredientes esenciales: Hardware, Data e Investigación

Transformer y Generative AI (2017 - ...)

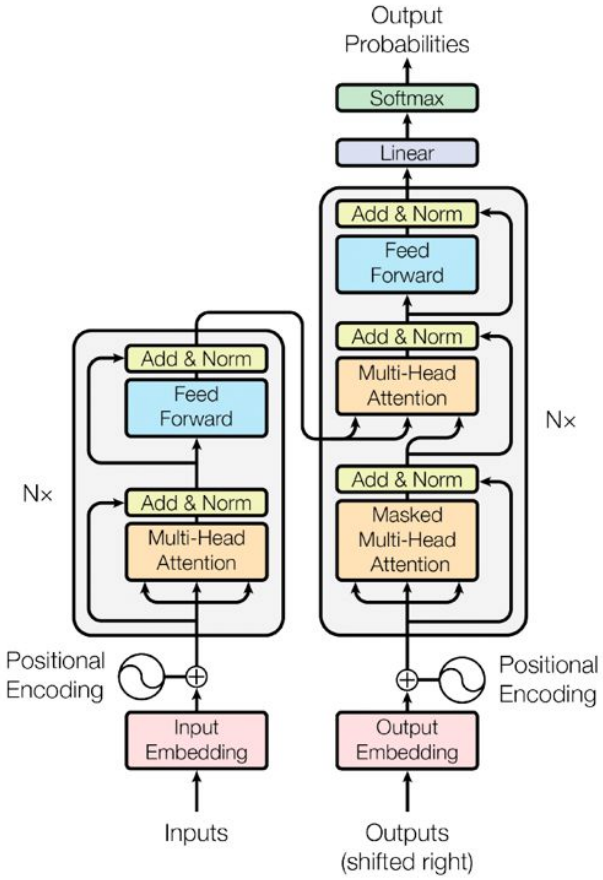

En 2017 se presenta el paper "Attention is All You Need" donde se propone la arquitectura Transformer, marcando así el inicio de Generative AI.

Generative AI (2017 - ...)

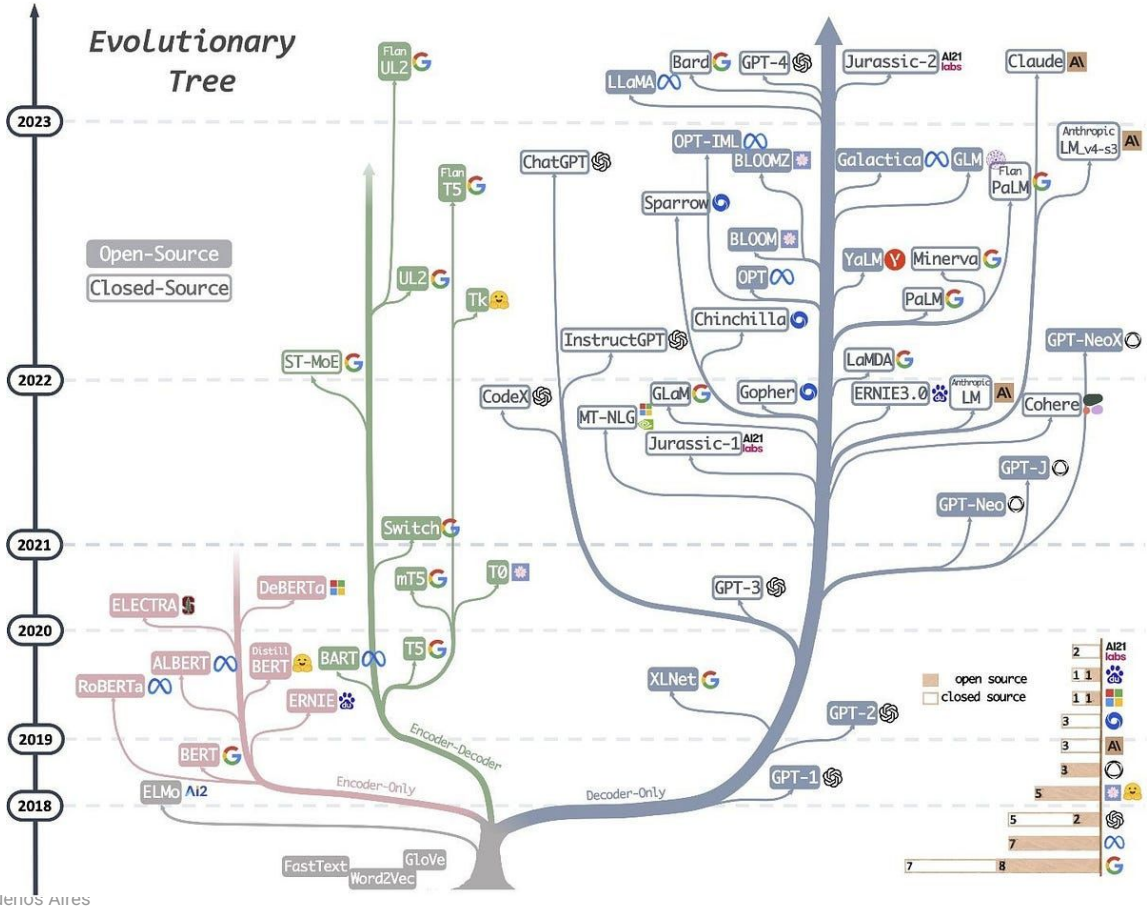

Resumen

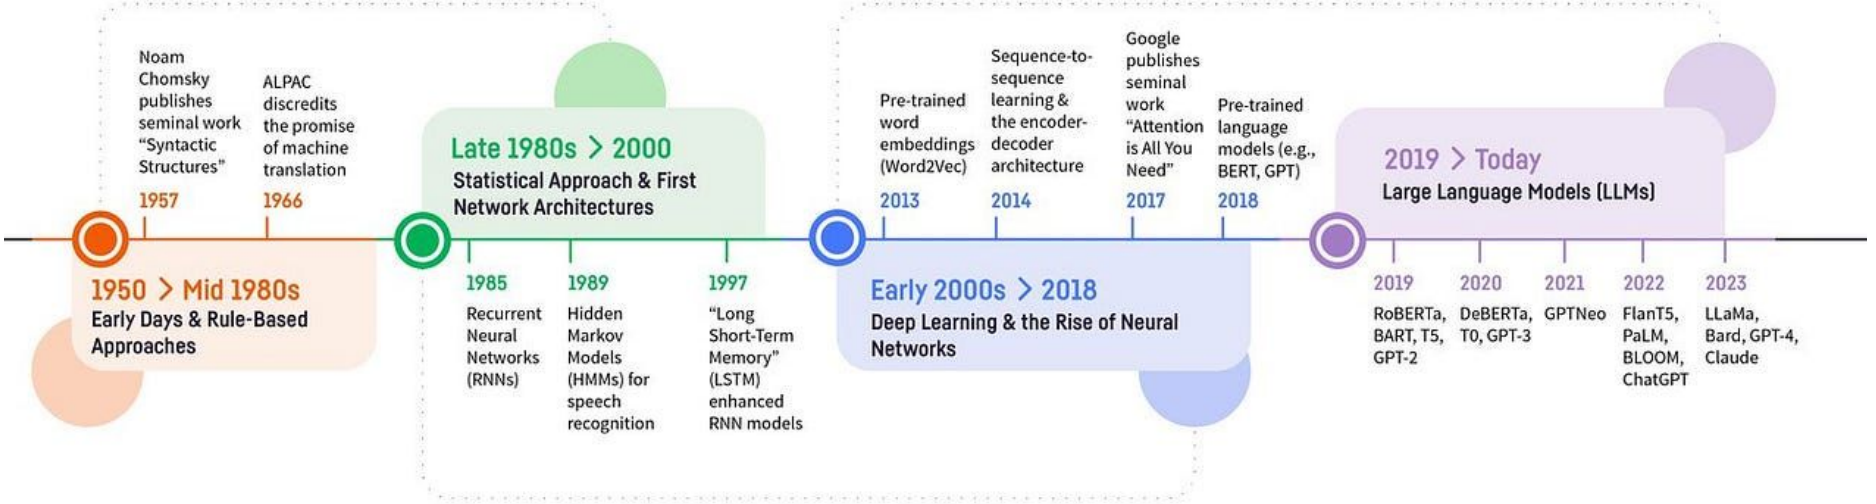

Créditos: Dataiku

Aplicaciones de NLP

Machine Translation

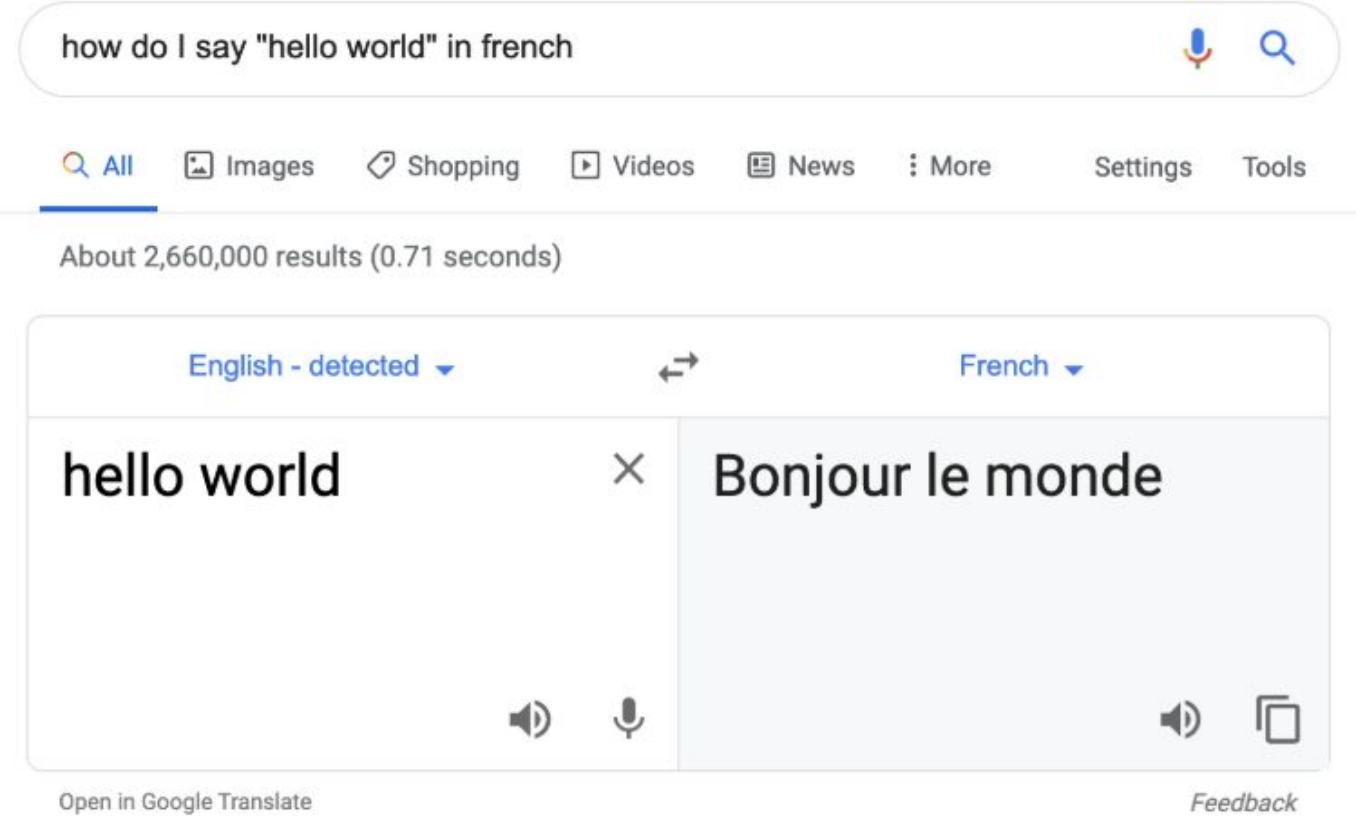

Asistentes de Voz

Clasificación de Texto

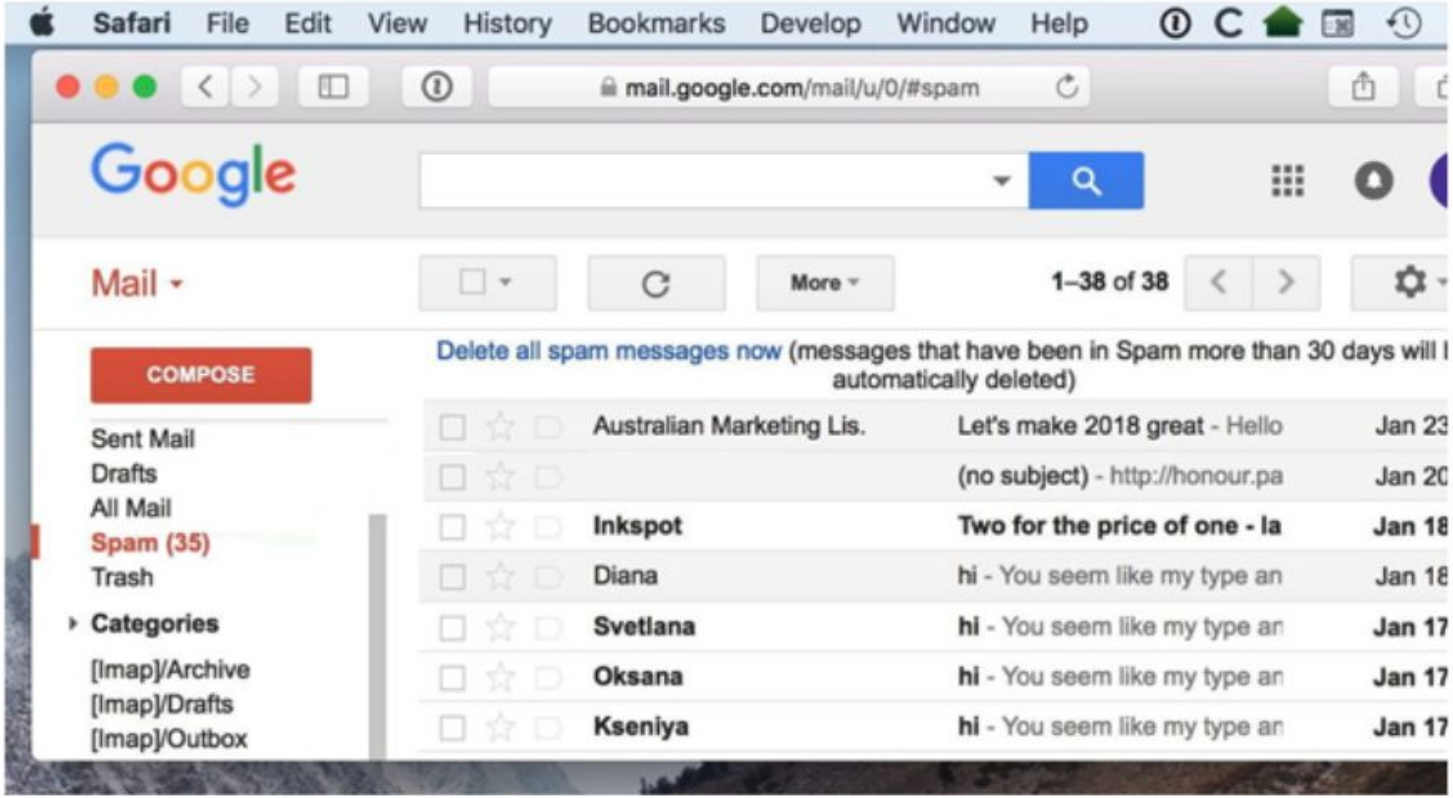

Chatbot

Hola!
hola simsimi
h
eres mi unico amigo
creeme que me gustaria dejarte en visto pero esta wea es mi pega

Tareas de NLP

Clasificación

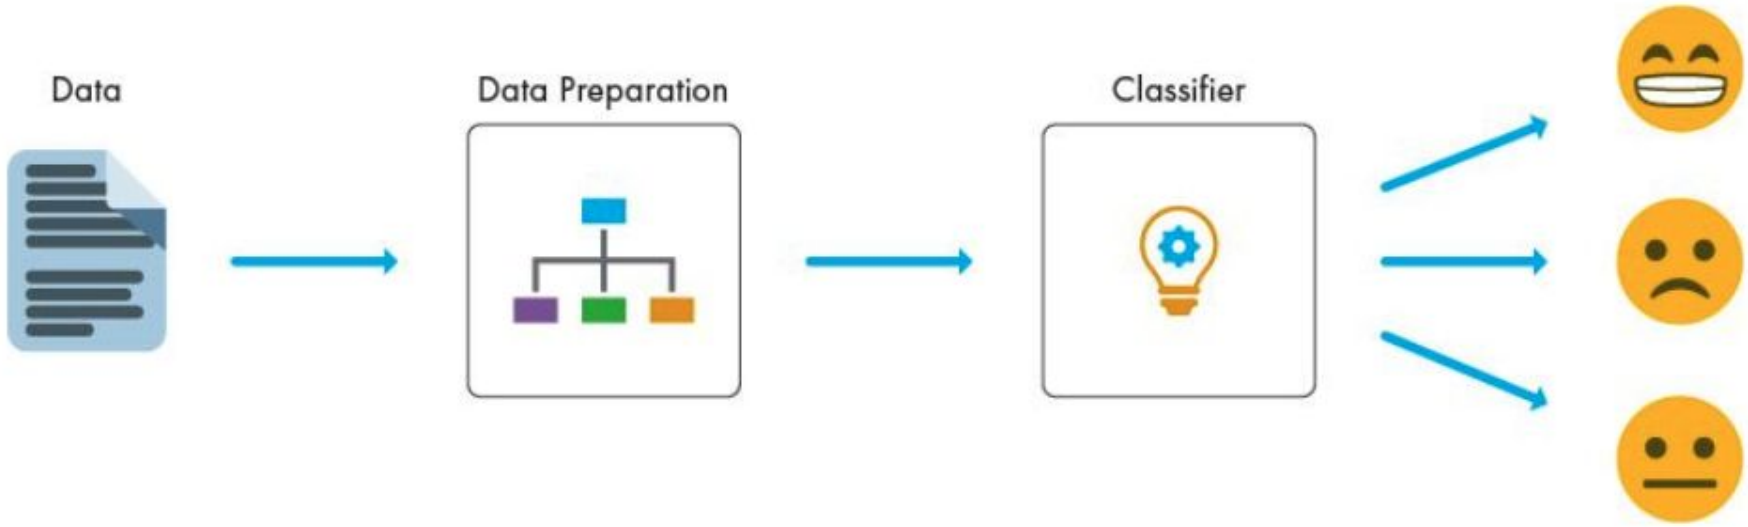

Tagging

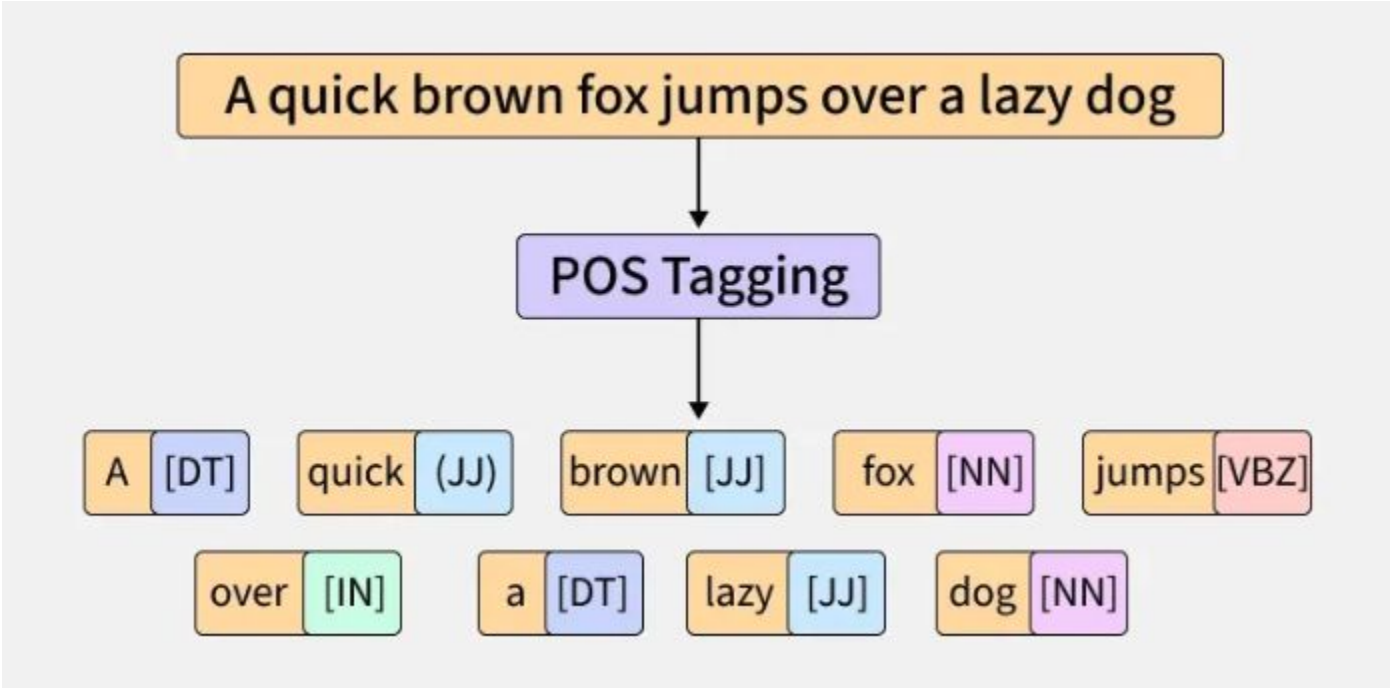
A quick brown fox jumps over a lazy dog
POS Tagging
A [DT]
quick (JJ)
brown [JJ]
fox [NN]
jumps [VBZ]
over [IN]
a [DT]
lazy [JJ]
dog [NN]

Tagging

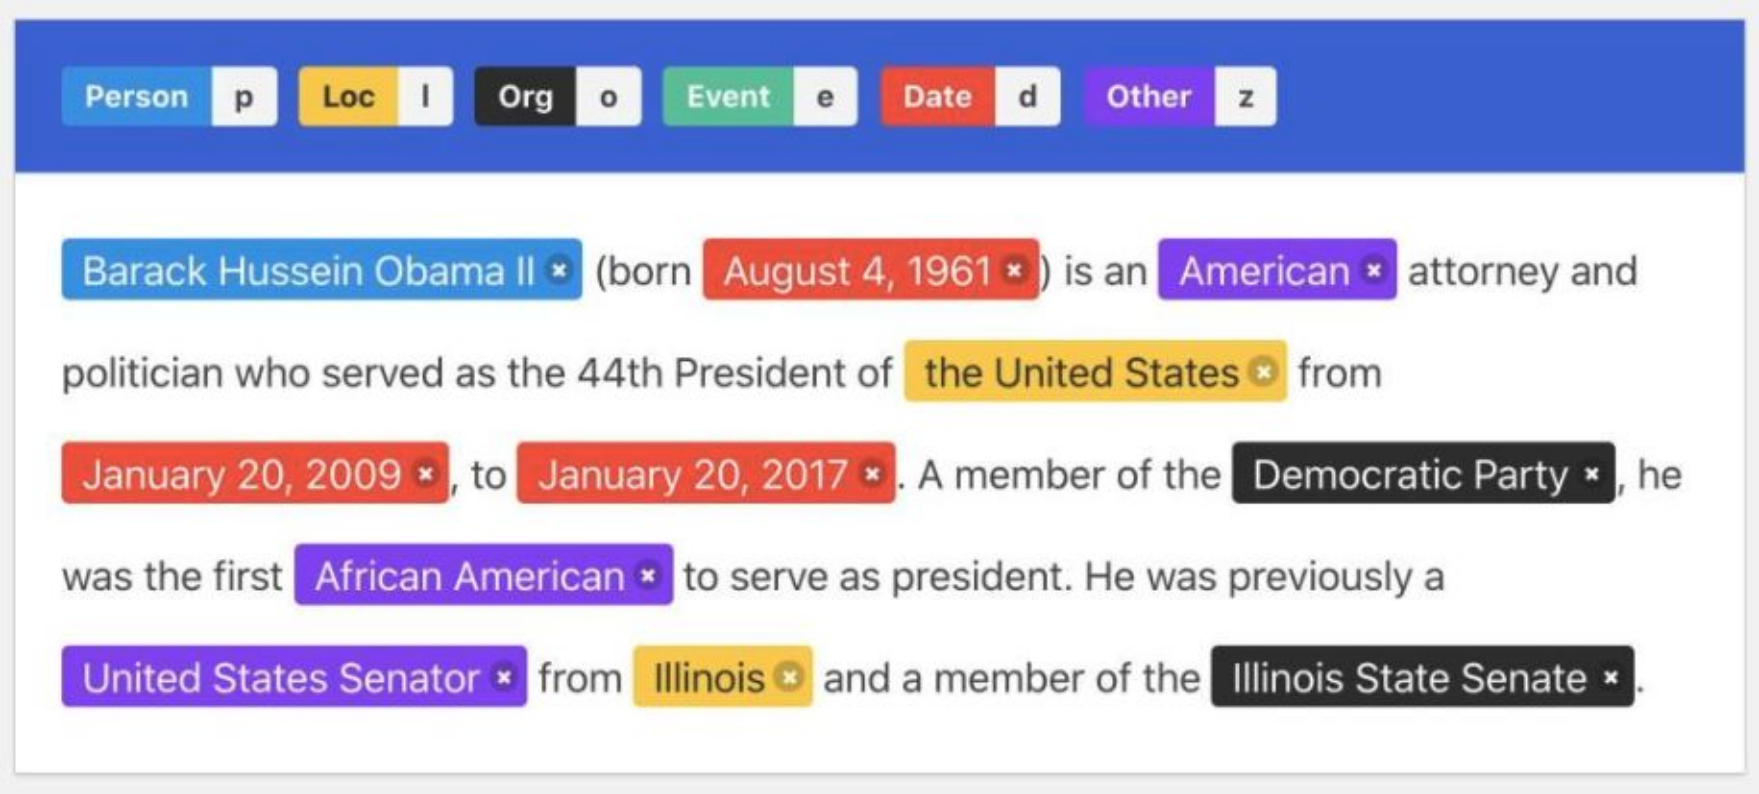
Person p
Loc l
Org o
Event e
Date d
Other z
Barack Hussein Obama II (born August 4, 1961) is an American attorney and politician who served as the 44th President of the United States from January 20, 2009, to January 20, 2017. A member of the Democratic Party, he was the first African American to serve as president. He was previously a United States Senator from Illinois and a member of the Illinois State Senate.

Autocompletado

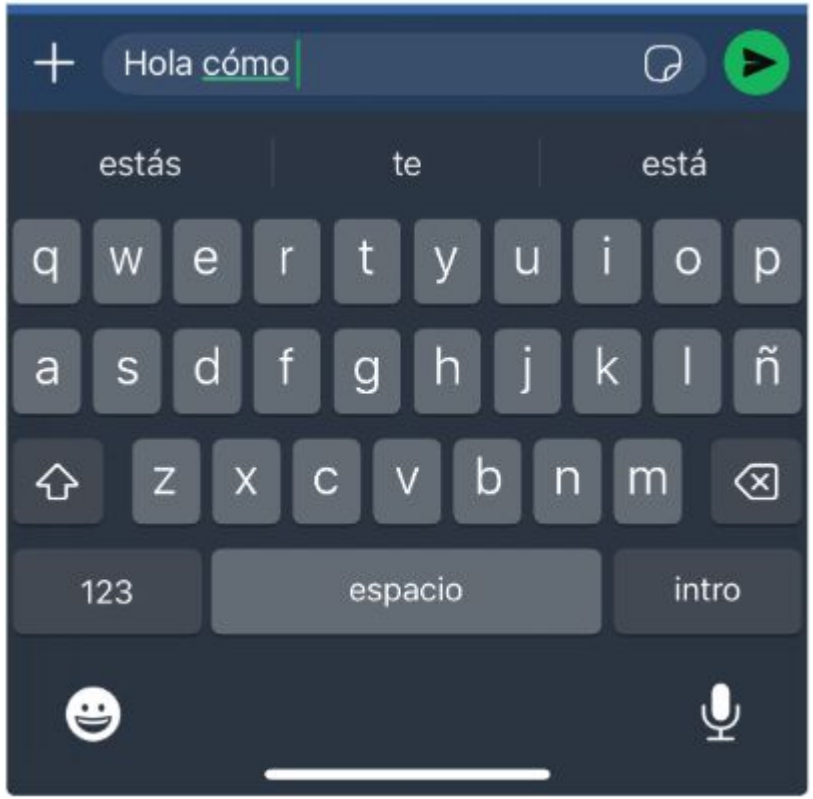

Generación de texto

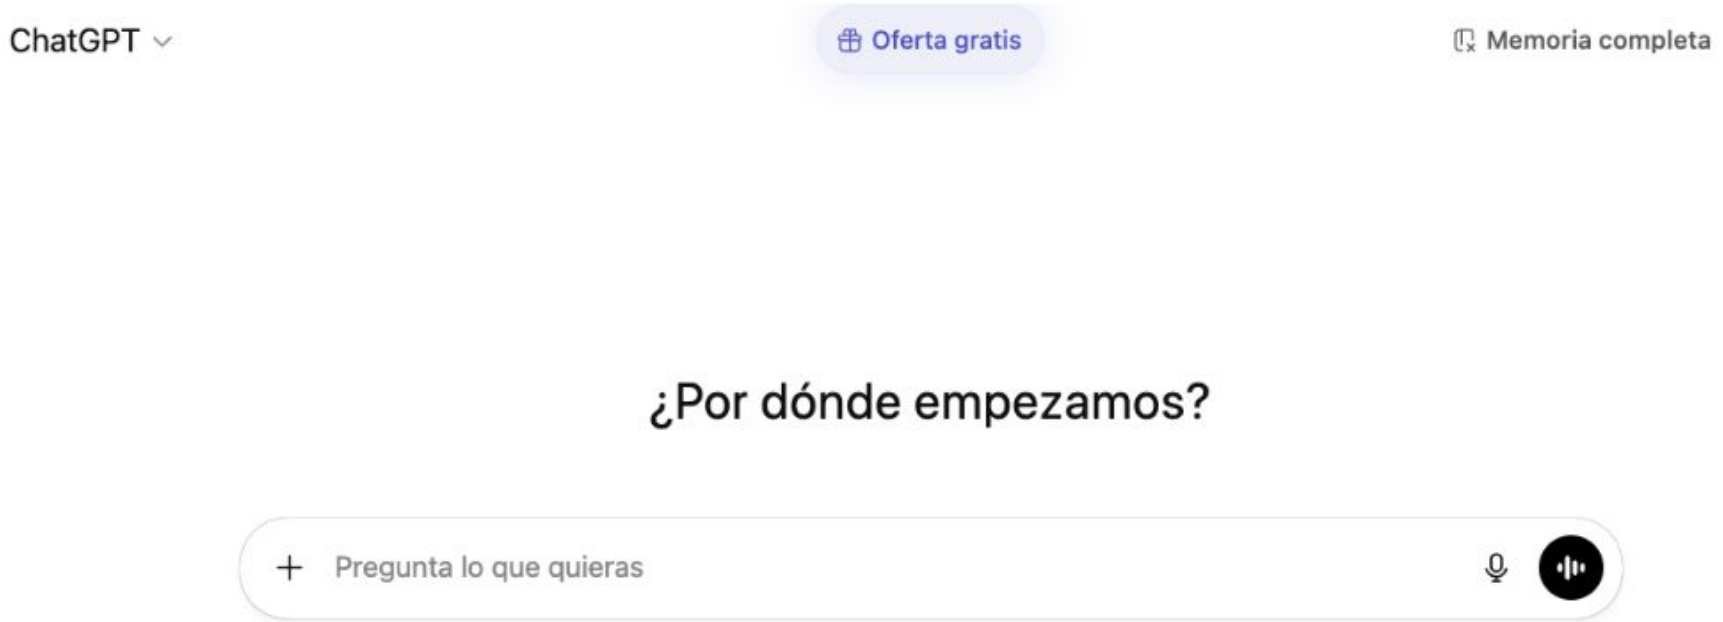

Summarization

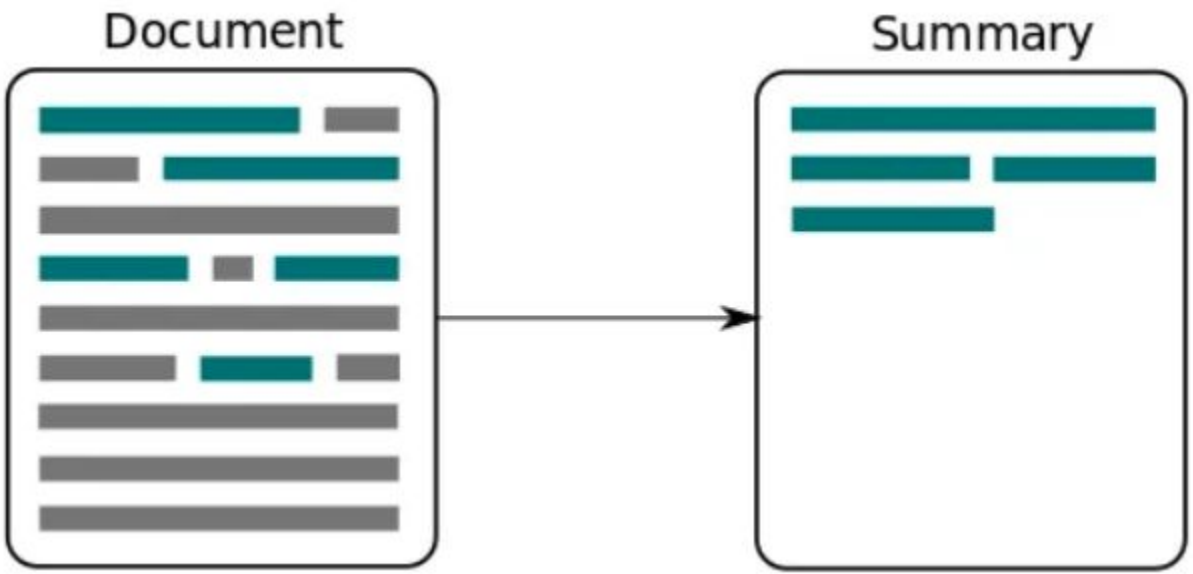

Multimodalidad

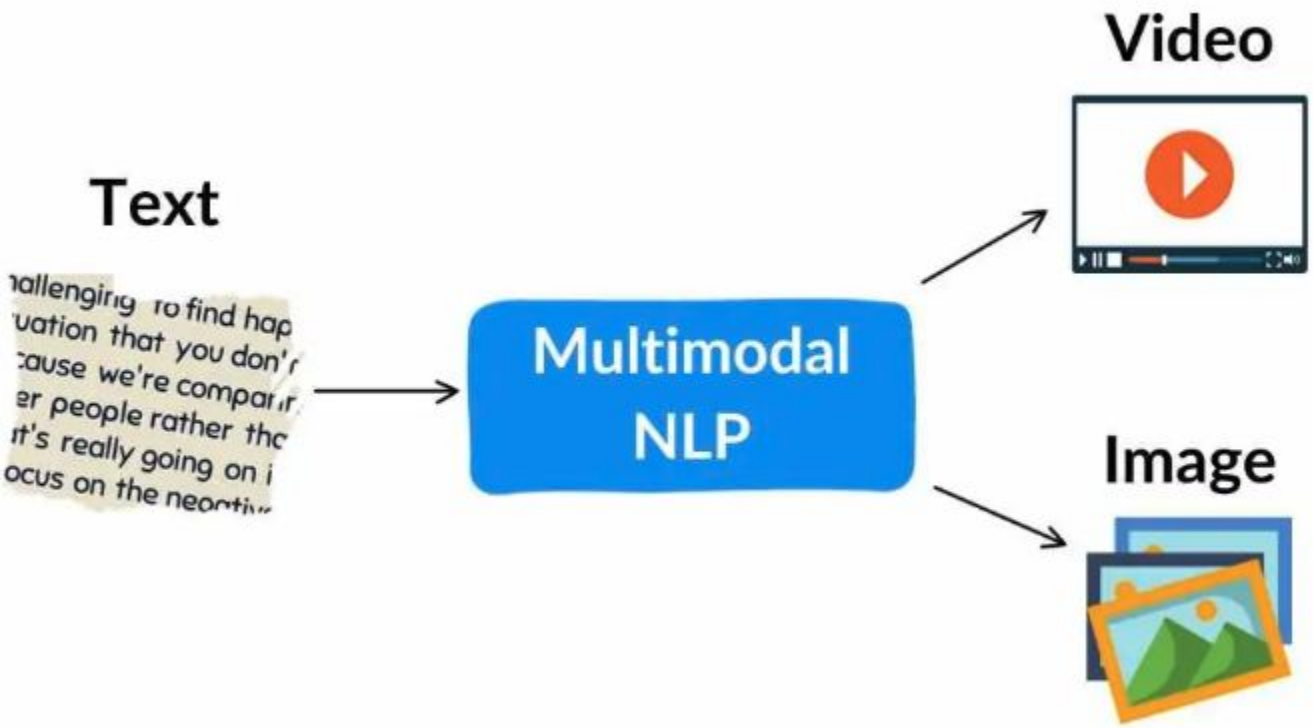

Tareas de NLP

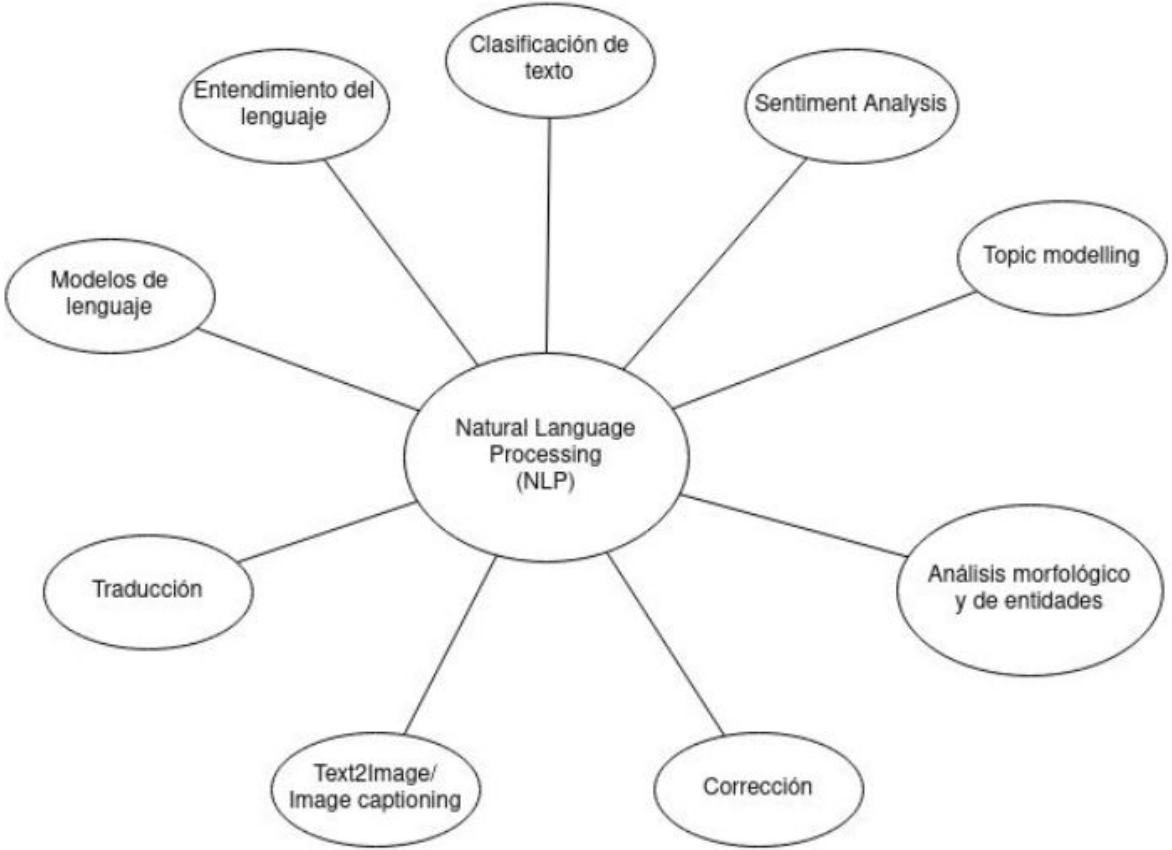

Preprocesamiento de texto

Preprocesamiento de texto

LINK GLOSARIO

corpus

Preprocessing

- Tokenization
- Punctuation removal
- Numbers removal
- HTML or special signs removal
- Lemmatization
- Stop words removal
- ...

Feature Engineering

- Bag of Words
- Words Embeddings
- ...

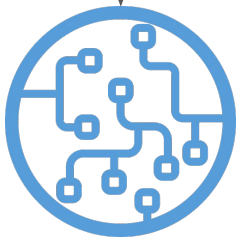

Build model

Normalización básica

- Lowercasing
- Eliminar signos de puntuación
- Quitar caracteres raros

The dogs are #running!! → **Normalización básica** → the dogs are running

Tokenization

Proceso en el cual una oración o documento es segmentado en términos individuales. Una vez finalizada la segmentación cada término único es referenciado mediante un token.

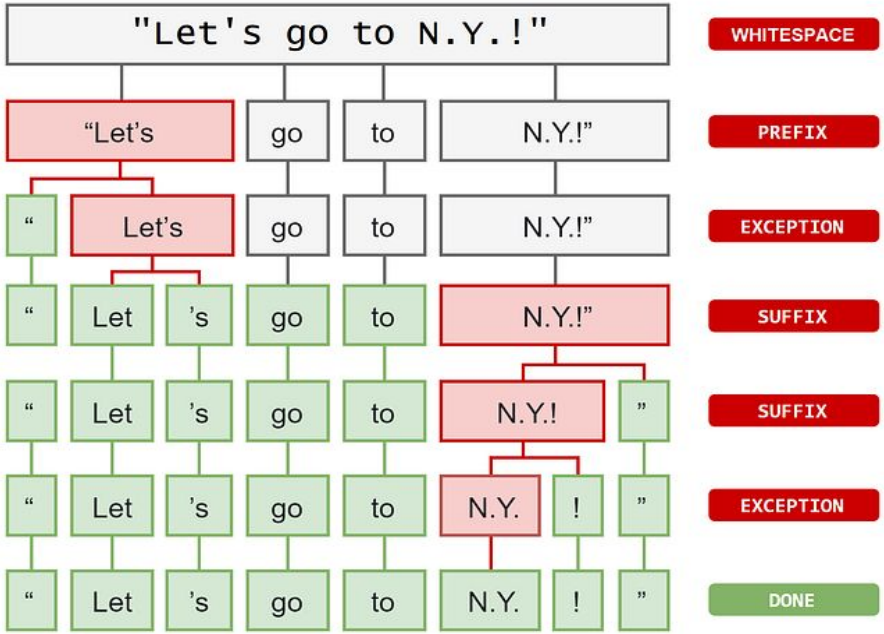

Tokenization

A primera vista parece que tokenizar es “solo hacer split”, pero tenemos los siguientes escenarios:

- abreviaturas como **D.C.**
- nombres compuestos como **New York**
- contracciones como **“doesn’t”** ó **“could't've”**
- nombres como **“SARS-Cov-2”** o **“R2-D2”**
- con idiomas como el **chino**, que no tienen espacios en blanco
- o idiomas como el **turco**, donde una sola palabra puede expresar tanta información como una oración completa

Tokenization

the dogs are running → **Tokenization** → [the, dogs, are, running]

Stemming

Aplica reglas de eliminación de patrones recurrentes de la lengua. El resultado es una palabra truncada que no será necesariamente la raíz morfológica de la palabra.

Regla: Eliminar los sufijos

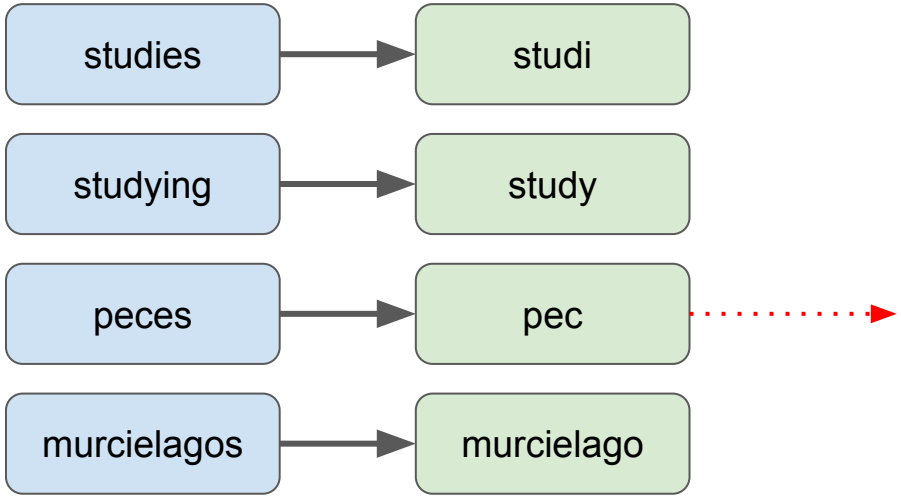

plural irregular

especimen, especímenes
régimen, regímenes

Stemming

[the, dogs, are, running] → **Stemming** → [the, dog, are, runn]

Lematización (lemmatization)

Devuelve la raíz morfológica de una palabra. Para ello se necesita un diccionario del idioma con todas las declinaciones posibles de las palabras raíz.

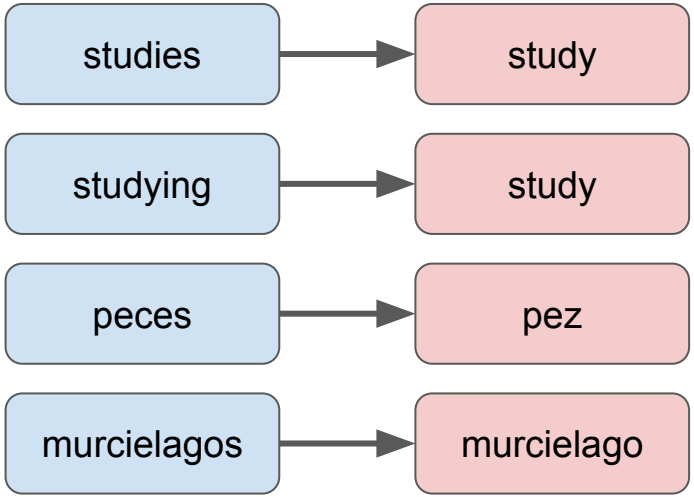

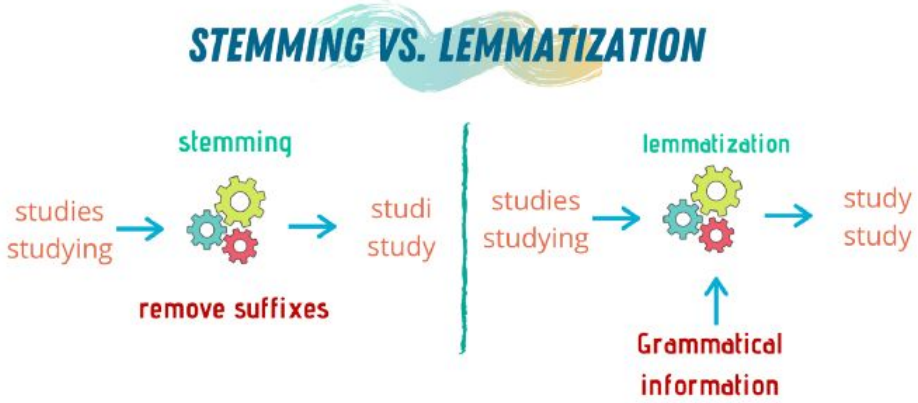

Lematización (lemmatization)

[the, dogs, are, running] → **Lemmatization** → [the, dog, be, run]

Stemming vs Lemmatization

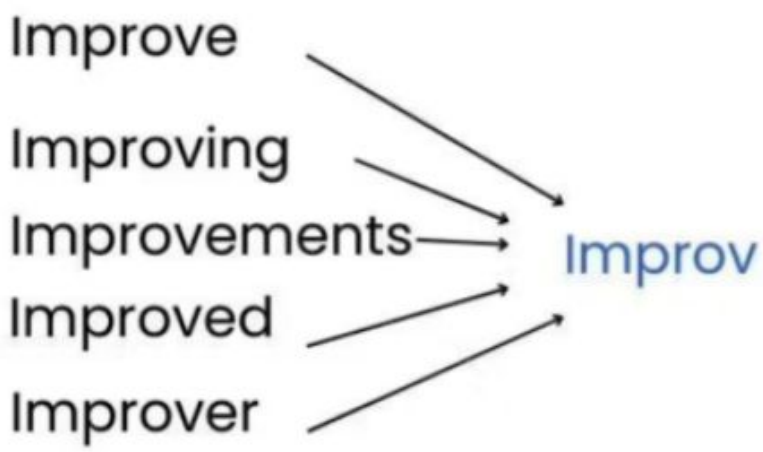

Stemming

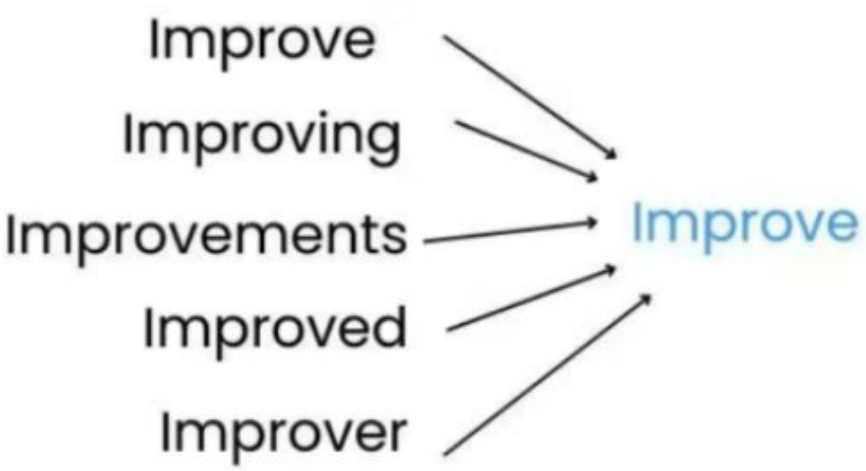

Lemmatization

Stemming vs Lemmatization

Stemming

Ventajas: Rápido y simple.

Desventajas: Puede producir raíces no válidas y perder precisión semántica.

Lemmatization

Ventajas: Produce palabras válidas y mantiene la precisión semántica.

Desventajas: Puede ser más lenta y requiere recursos adicionales (como WordNet).

Practiquemos lo visto hasta ahora

Link al Colab

LINK

Vectorización de Texto

Vectorización de texto

LINK GLOSARIO

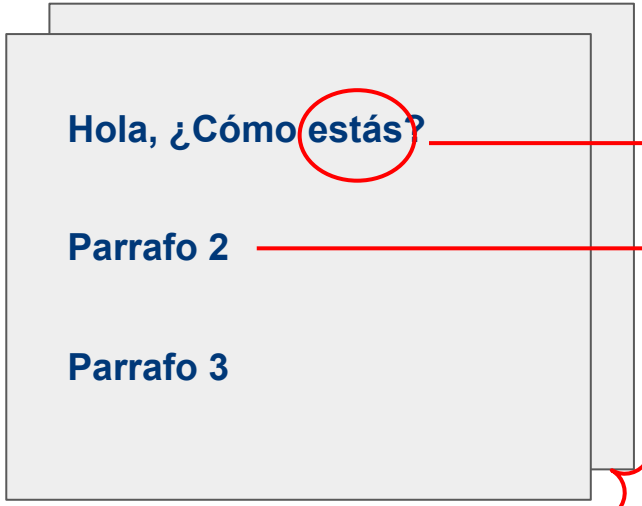

Término t: palabra/símbolo "t" del documento

Document: su largo es variable, normalmente una sentencia/oración/párrafo.

Corpus: conjunto de documentos, forman todo el vocabulario.

No podemos ingresar texto a una red
¿Cómo transformamos palabras a números?

vectorización →

Vectores de palabras/documentos

Vectores de frecuencia/conteo

"Por cada documento en el corpus se calcula un vector que representa cuántas veces cada palabra del vocabulario aparece en ese documento"

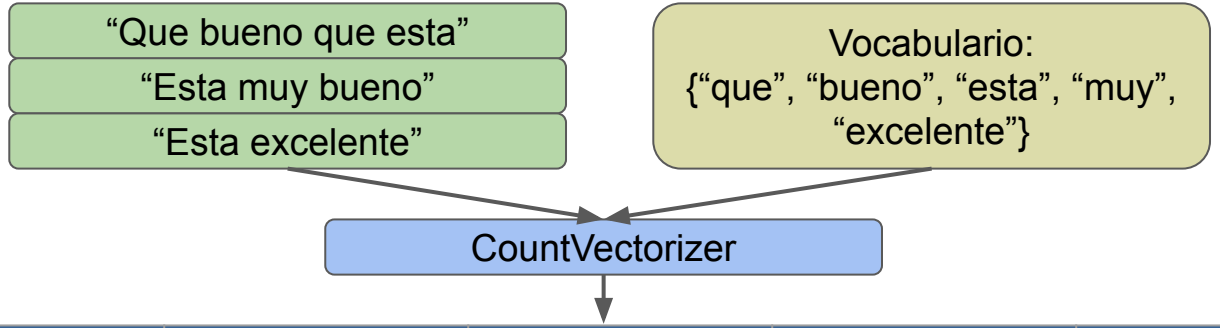

que	bueno	esta	muy	excelente
2	1	1	0	0
0	1	1	1	0
0	0	1	0	1

Los vectores tienen el tamaño del vocabulario

Bolsa de palabras (BOW)

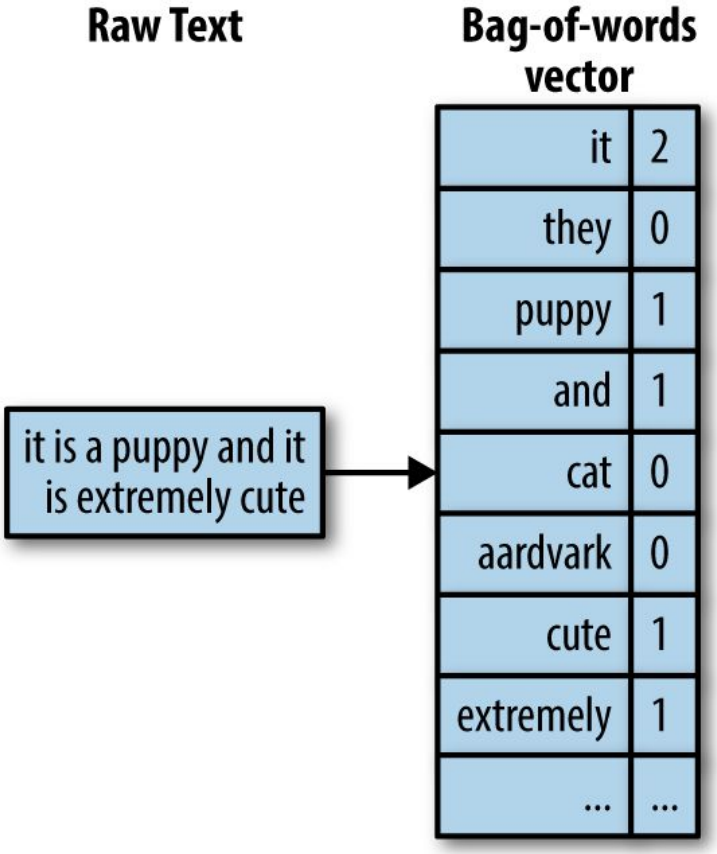

Bag of Words representa un documento mediante un vector basado en la presencia o frecuencia de palabras del vocabulario, ignorando el orden en el que aparecen.

Bolsa de palabras (BOW)

Corpus:

The dog is happy. The child makes the dog happy. The dog makes the child happy

↓

Tokenization:

D1: [The] [dog] [is] [happy]
D2: [The] [child] [makes] [the] [dog] [happy]
D3: [The] [dog] [makes] [the] [child] [happy]

↓

Documents	Counting word frequencies
D1	the: 1, dog: 1, is: 1, happy: 1
D2	the: 2, dog: 1, makes: 1, child: 1, happy: 1
D3	the: 2, child: 1, makes: 1, dog: 1, happy: 1

↓

Encode	child	dog	happy	is	makes	the	BoW Vector representations
D1	0	1	1	1	0	1	[0,1,1,1,0,1]
D2	1	1	1	0	1	2	[1,1,1,0,1,2]
D3	1	1	1	0	1	2	[1,1,1,0,1,2]

Bag of Words representa un documento mediante un vector basado en la presencia o frecuencia de palabras del vocabulario, **ignorando el orden en el que aparecen.**

Bolsa de palabras (BOW)

Document D1	*The child makes the dog happy* the: 2, dog: 1, makes: 1, child: 1, happy: 1
Document D2	*The dog makes the child happy* the: 2, child: 1, makes: 1, dog: 1, happy: 1

↓

	child	dog	happy	makes	the	BoW Vector representations
D1	1	1	1	1	2	[1,1,1,1,2]
D2	1	1	1	1	2	[1,1,1,1,2]

Bag of Words representa un documento mediante un vector basado en la presencia o frecuencia de palabras del vocabulario, **ignorando el orden en el que aparecen.**

Vectores Binary Bag of Words

"Por cada documento en el corpus se calcula un vector que representa si cada palabra del vocabulario aparece o no en ese documento"

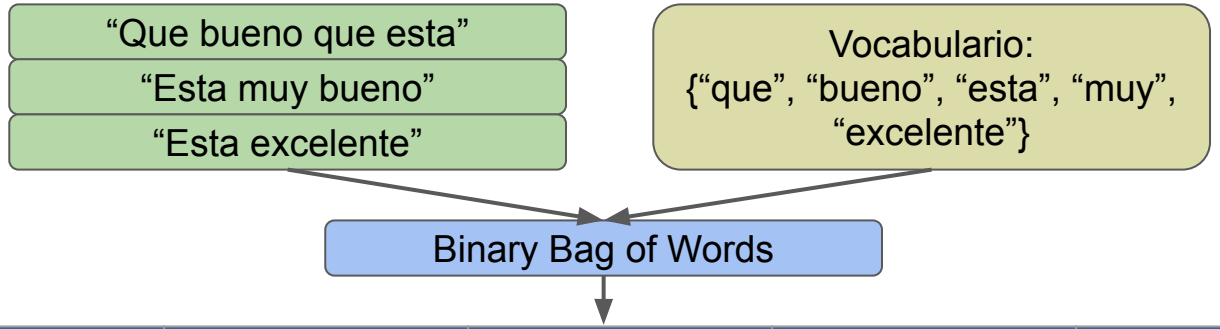

que	bueno	esta	muy	excelente
1	1	1	0	0
0	1	1	1	0
0	0	1	0	1

Stop words

Palabras que no aportan valor al significado de una oración ya que son muy frecuentes o comunes en el lenguaje

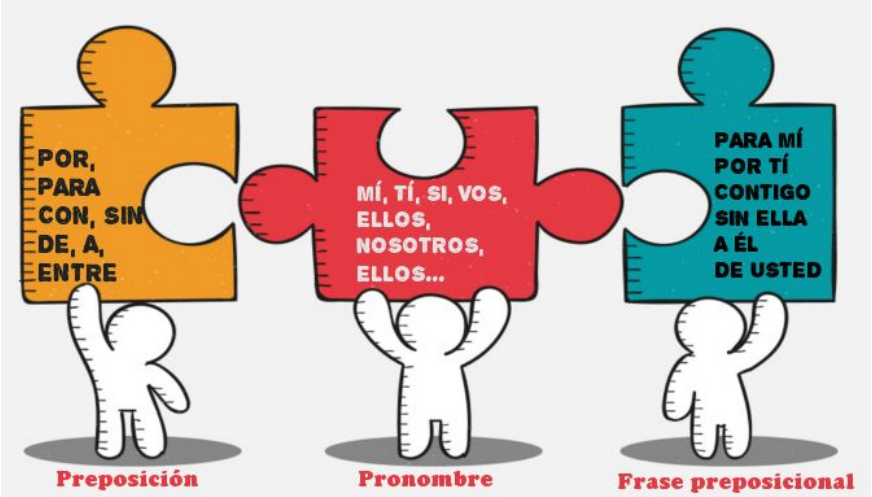

*Argentina, oficialmente, República Argentina, es **un** país soberano **de** América **del** Sur, ubicado **en el** extremo sur **y** sudeste **de** dicho subcontinente. Adopta **la** forma **de** gobierno republicana, democrática, representativa **y** federal.*

Argentina, oficialmente, República Argentina, es país soberano América Sur, ubicado extremo sur sudeste dicho subcontinente. Adopta forma gobierno republicana, democrática, representativa federal.

Stop words

Analizar un texto relacionado con calentamiento global (global climate)

Texto con Stop Words

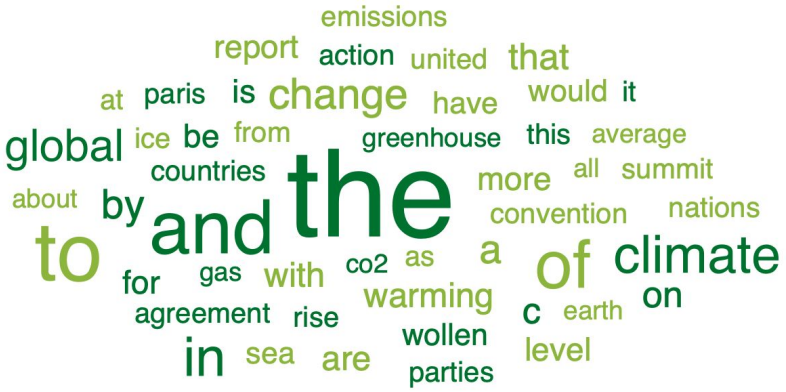

Texto sin Stop Words

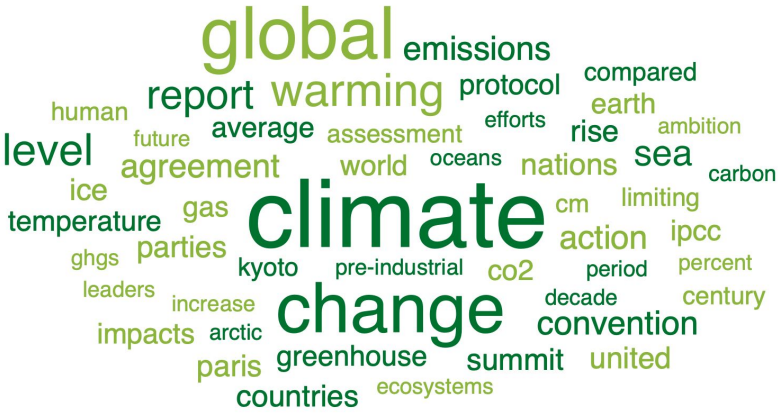

Las Stop Words pueden depender del contexto del corpus.

Stop words

Zipf's Law

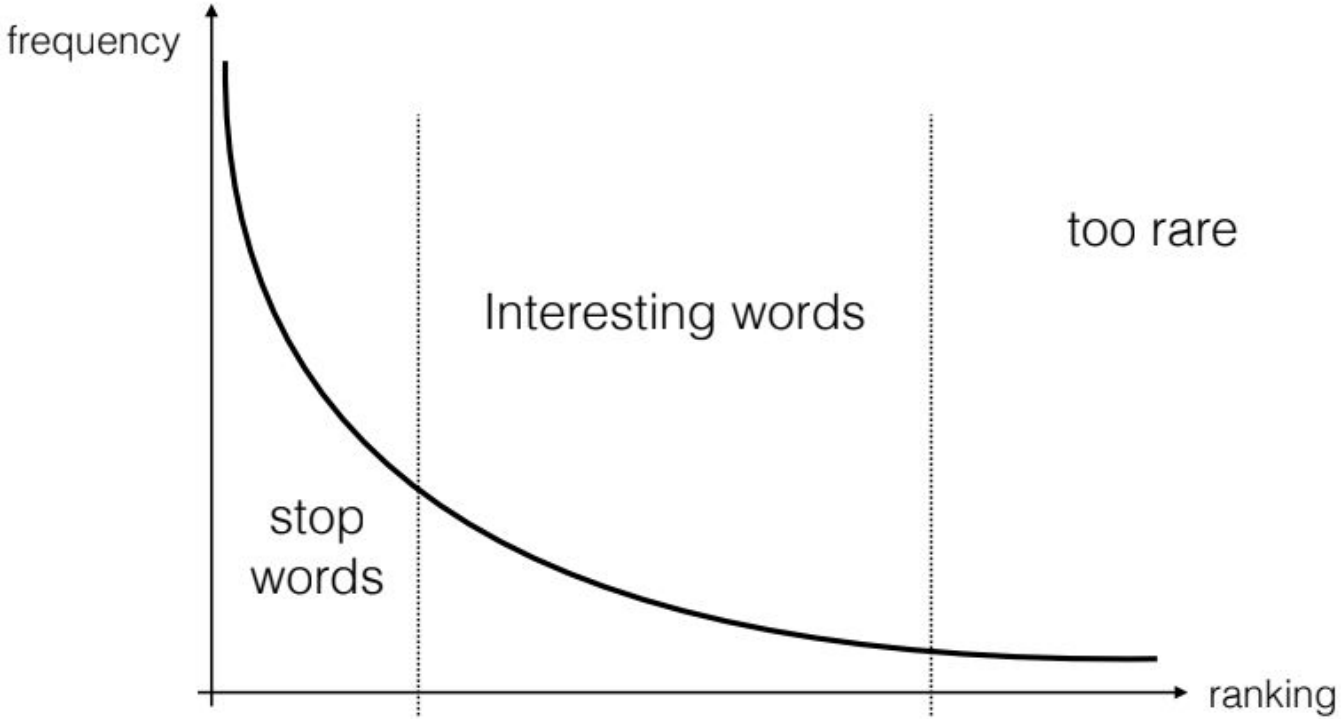

TF-IDF (Term frequency-Inverse document frequency)

Se utiliza como indicador de cuán importante es una palabra (término) en un documento.

$$\text{TF-IDF}_{(n,d)} = \text{TF}_{(n,d)} \times \text{IDF}_{(n)}$$

- $\text{TF-IDF}_{(n,d)}$: Peso de un término (n) en un documento (d)
- $\text{TF}_{(n,d)}$: Frecuencia de aparición de un término (n) en un documento (d)
- $\text{IDF}_{(n)}$: Factor IDF de un término (n)

Vector IDF (Inverse Document Frequency)

"Proporción de documentos en el corpus que poseen el término"

También suele utilizarse el logaritmo en base 2, su función es conseguir un coeficiente bajo, fácil de manejar

N es el número total de documentos de la colección.

$$IDF_{(n)} = \log_{10} \frac{N}{DF_{(n)}}$$

DF (Document Frequency) es el número documentos en los que aparece el término (n) a lo largo de toda la colección

Si el término aparece en todos los documentos el IDF será cero (es popular y por lo tanto aporta poco valor)

Vector IDF

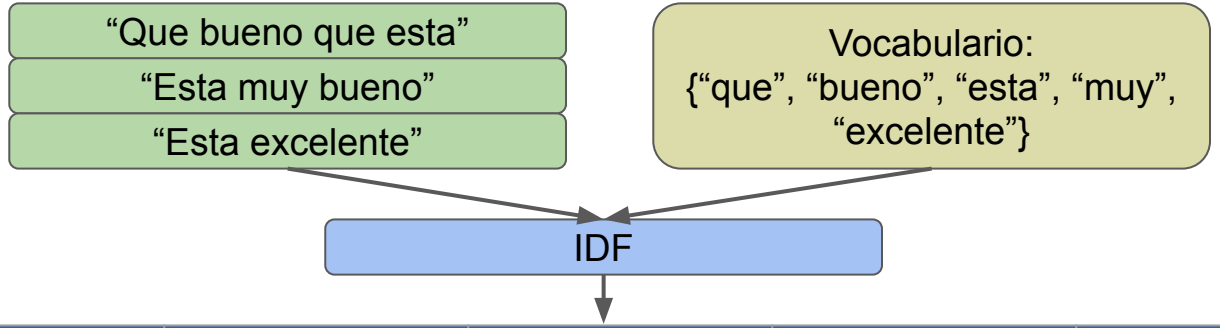

que	bueno	esta	muy	excelente
log(3/1)	log(3/2)	log(3/3)	log(3/1)	log(3/1)

que	bueno	esta	muy	excelente
0.477	0.176	0	0.477	0.477

Se obtiene como la división de la cantidad de documentos sobre la suma en axis=0 (vertical) del CountVectorizer.

Vector TF-IDF

“Que bueno que esta”
“Esta muy bueno”
“Esta excelente”

Vocabulario:
{“que”, “bueno”, “esta”, “muy”, “excelente”}

IDF

que	bueno	esta	muy	excelente
log(3/1)	log(3/2)	log(3/3)	log(3/1)	log(3/1)

TF-IDF

que	bueno	esta	muy	excelente
2 * log(3/1)	1 * log(3/2)	1 * log(3/3)	0 * log(3/1)	0 * log(3/1)
0 * log(3/1)	1 * log(3/2)	1 * log(3/3)	1 * log(3/1)	0 * log(3/1)
0 * log(3/1)	0 * log(3/2)	1 * log(3/3)	0 * log(3/1)	1 * log(3/1)

Similitud entre documentos

¿Cómo medimos qué tan parecidos son dos textos o palabras comparando el significado de sus vectores?

En NLP clásico (TF-IDF, BoW):

- Palabras frecuentes pueden tener vectores con mayor norma.

Si usamos Euclidiana:

- Documentos largos parecen más lejos
- Palabras frecuentes dominan

Coseno normaliza eso.

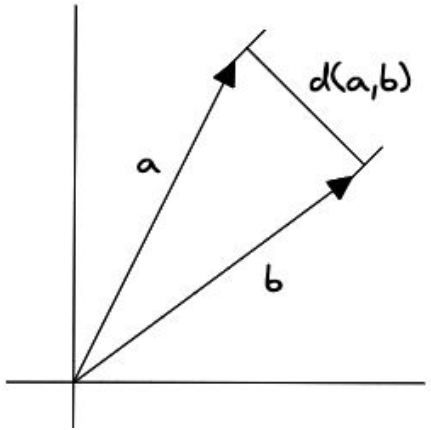

Distancia Euclideana

$$d(x, y) = \sqrt{\sum_{i=1}^{n} (y_i - x_i)^2}$$

Mide distancia absoluta en el espacio. Depende fuertemente de la magnitud.

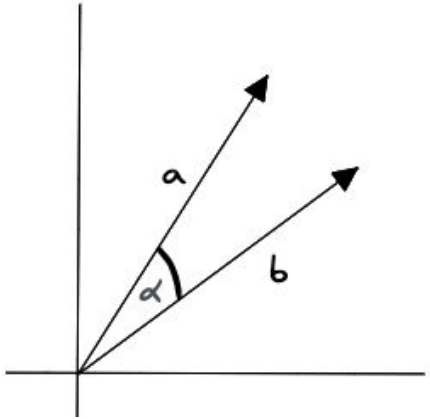

Similitud Coseno

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|}$$

Mide el ángulo entre vectores. Ignora la magnitud y compara orientación.

Similitud coseno

"Se utiliza para evaluar la dirección de dos vectores"

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2}\sqrt{\sum_{i=1}^{n} B_i^2}}$$

Similitud coseno = 1 → los vectores tienen la misma dirección.
Similitud coseno = 0 → los vectores son ortogonales.
Similitud coseno = -1 → los vectores apuntan en sentido contrario.

Intuición de la similitud coseno

Doc1

"Cada equipo en el campo tiene hasta once jugadores…"

Doc2

"... el equipo Argentino presentó a todos sus jugadores titulares… "

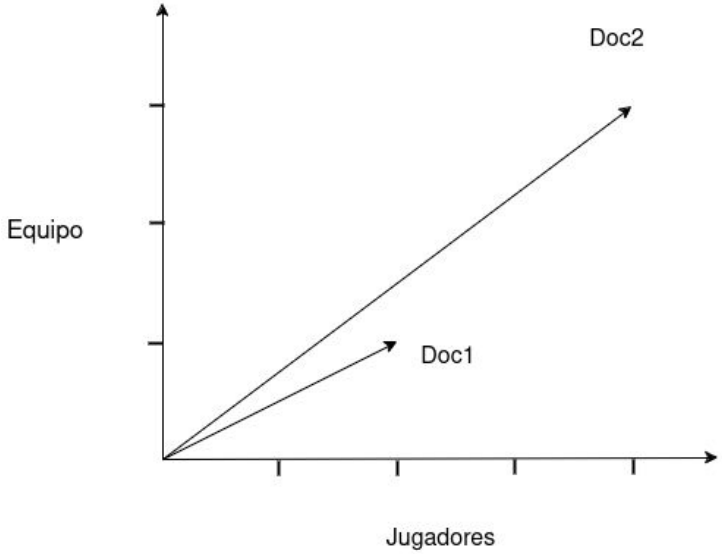

Para la distancia euclidea, los documentos son muy distintos. Para la similitud coseno, son similares.

Co-Ocurrence Matrix

Una co-occurrence matrix (matriz de co-ocurrencia) es una representación que cuenta cuántas veces dos palabras aparecen juntas dentro de un mismo contexto (por ejemplo, una ventana de palabras).

A diferencia de Bag of Words, que representa documentos, la matriz de co-ocurrencia representa relaciones entre palabras.

context words:
4 words to the left +
4 words to the right

is traditionally followed by	**cherry**	pie, a traditional dessert
often mixed, such as	**strawberry**	rhubarb pie. Apple pie
computer peripherals and personal	**digital**	assistants. These devices usually
a computer. This includes	**information**	available on the internet

	aardvark	...	computer	data	result	pie	sugar	...
cherry	0	...	2	8	9	442	25	...
strawberry	0	...	0	0	1	60	19	...
digital	0	...	1670	1683	85	5	4	...
information	0	...	3325	3982	378	5	13	...

¡Tambien nos da representaciones sparse!

Para solucionar la sparsidad, normalmente se aplican técnicas como:

- Reducción de dimensionalidad (SVD)
- Factorización de matrices (idea de GloVe)

Esparsidad de los vectores de conteos

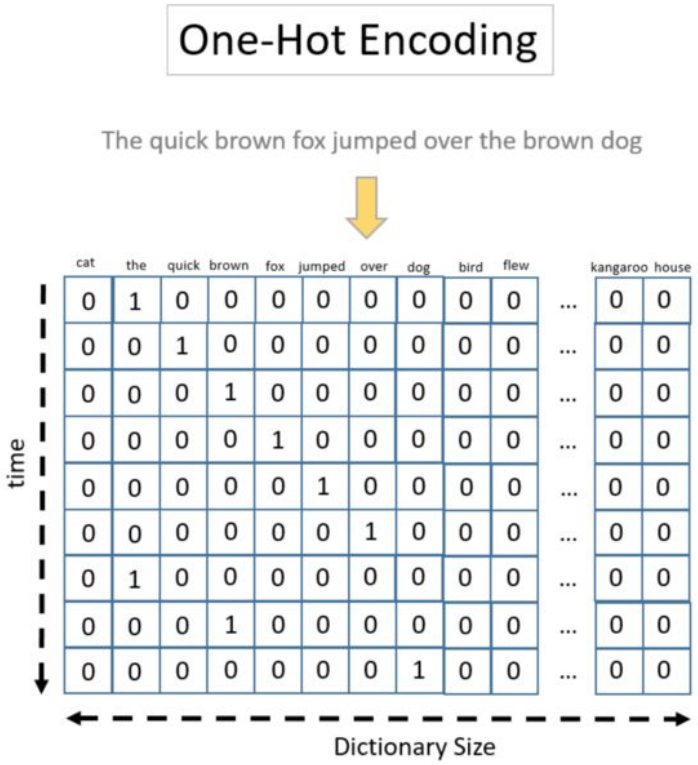

¡El idioma inglés tiene más de 180.000 palabras en su vocabulario en uso!

¡La representación es sumamente rala! (poco densa)

No estamos aprovechando eficientemente la dimensionalidad del espacio de vectores.

Machine Learning para NLP

Modelo de clasificación de texto

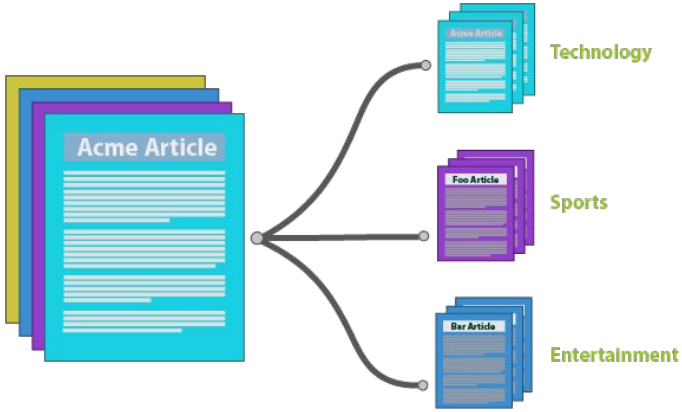

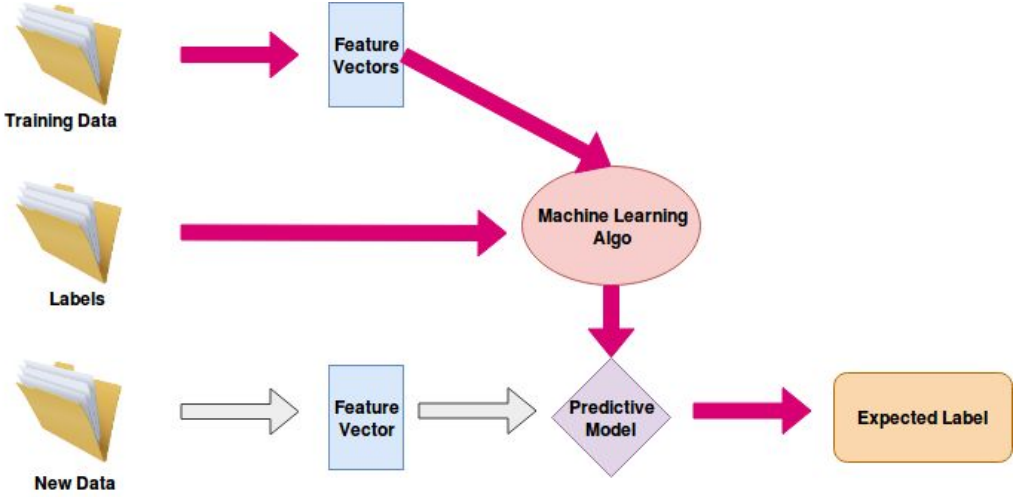

Modelo de clasificación, Naïve Bayes

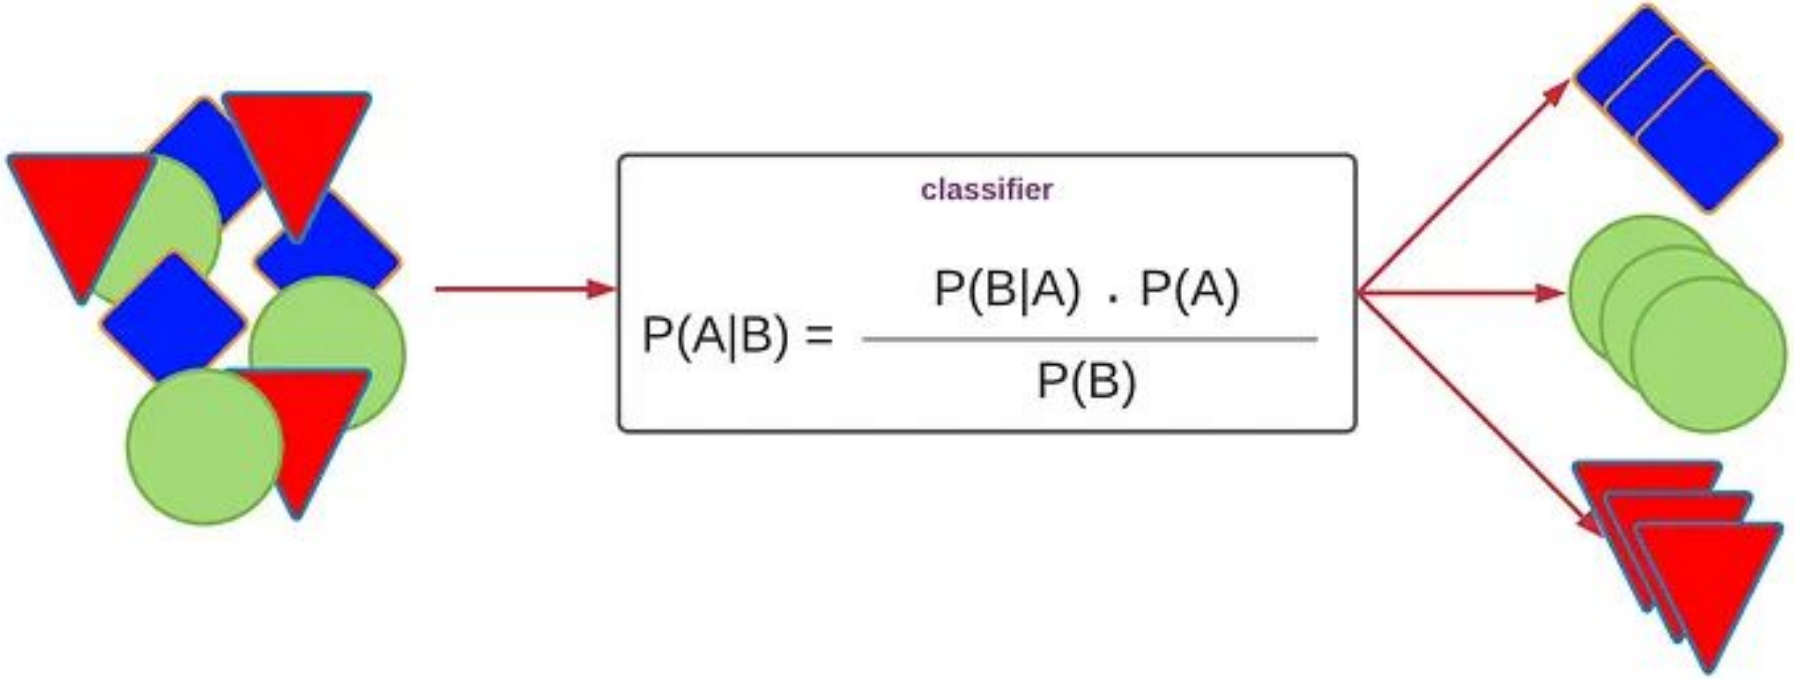

Modelo de clasificación, Naïve Bayes

Usaremos Naive Bayes (Multinomial).

Queremos clasificar una frase como: $\begin{cases} \text{Positivo} \\ \text{Negativo} \end{cases}$

Los pasos que seguiremos serán:

- **Paso 1:** Obtenemos dataset de entrenamiento
- **Paso 2:** Construimos el vocabulario
- **Paso 3:** Calculamos probabilidades a priori
- **Paso 4:** Realizamos conteo de palabras por clase
- **Paso 5:** Aplicamos Laplace Smoothing
- **Paso 6:** Clasificamos una nueva frase

Modelo de clasificación, Naïve Bayes

Paso 1: Obtenemos dataset de entrenamiento

Clase Positivo (2 documentos)

- "me gustó la película"
- "excelente película"

Clase Negativo (2 documentos)

- "mala película"
- "Película horrible"

Modelo de clasificación, Naïve Bayes

Paso 2: Construimos el vocabulario

```
"me gustó la
película", "excelente
película", "mala
película", "Película
horrible"
```

Normalización de Texto + Tokenización

```
[me,gustó,la,película],
[excelente,película][exce
lente, película],
[excelente,película],
[mala,película][mala,
película][mala,película],
[película,horrible][pelíc
ula,horrible][película,ho
rrible]
```

Modelo de clasificación, Naïve Bayes

Paso 2: Construimos el vocabulario

```
[me,gustó,la,película],
[excelente,película][exce
lente, película],
[excelente,película],
[mala,película][mala,
película][mala,película],
[película,horrible][pelíc
ula,horrible][película,ho
rrible]
```

Vocabulario

```
V={me,gustó,la,excelente,
mala,horrible,película}
```

$$|V| = 7$$

Modelo de clasificación, Naïve Bayes

Paso 3: Calculamos probabilidades a priori

Como hay 2 positivos y 2 negativos:

$$P(Positivo) = \frac{2}{4} = 0.5$$

$$P(Negativo) = \frac{2}{4} = 0.5$$

Clase Positivo (2 documentos)

- "me gustó la película"
- "excelente película"

Clase Negativo (2 documentos)

- "mala película"
- "Película horrible"

Modelo de clasificación, Naïve Bayes

Paso 4: Realizamos conteo de palabras por clase

Total palabras en clase Positivo:

$$N_{pos} = 6$$

Total palabras en clase Negativo:

$$N_{neg} = 4$$

Clase Positivo (2 documentos)

- "me gustó la película"
- "excelente película"

Clase Negativo (2 documentos)

- "mala película"
- "Película horrible"

Modelo de clasificación, Naïve Bayes

Paso 5: Laplace Smoothing

Fórmula general: $P(w|c) = \dfrac{\text{count}(w,c)+1}{N_c + |V|}$

Probabilidades en Positivo

$$N_{pos} + |V| = 6 + 7 = 13$$

Ejemplos:

$$P(excelente|Pos) = \frac{1+1}{13} = \frac{2}{13}$$

$$P(película|Pos) = \frac{2+1}{13} = \frac{3}{13}$$

$$P(mala|Pos) = \frac{0+1}{13} = \frac{1}{13}$$

Modelo de clasificación, Naïve Bayes

Paso 5: Laplace Smoothing

Fórmula general: $P(w|c) = \dfrac{\text{count}(w,c)+1}{N_c + |V|}$

Probabilidades en Negativo

$$N_{neg} + |V| = 4 + 7 = 11$$

Ejemplos:

$$P(mala|Neg) = \frac{1+1}{11} = \frac{2}{11}$$

$$P(película|Neg) = \frac{2+1}{11} = \frac{3}{11}$$

$$P(excelente|Neg) = \frac{0+1}{11} = \frac{1}{11}$$

Modelo de clasificación, Naïve Bayes

Paso 6: Clasificación de una nueva frase

Fórmula de Naive Bayes: $P(c|d) \propto P(c) \prod_i P(w_i|c)$

Nueva frase:

$d =$ "excelente película"

Para Positivo:

$$P(Pos|d) \propto P(Pos) \cdot P(excelente|Pos) \cdot P(película|Pos)$$

$$= 0.5 \cdot \frac{2}{13} \cdot \frac{3}{13} = \frac{3}{169}$$

Modelo de clasificación, Naïve Bayes

Paso 6: Clasificación de una nueva frase

Fórmula de Naive Bayes: $P(c|d) \propto P(c) \prod_i P(w_i|c)$

Nueva frase:

$d = \text{"excelente película"}$

Para Negativo:

$$P(Neg|d) \propto P(Neg) \cdot P(excelente|Neg) \cdot P(película|Neg)$$

$$= 0.5 \cdot \frac{1}{11} \cdot \frac{3}{11} = \frac{3}{242}$$

Modelo de clasificación, Naïve Bayes

Paso 6: Clasificación de una nueva frase

Fórmula de Naive Bayes: $P(c|d) \propto P(c) \prod_i P(w_i|c)$

Nueva frase:

$d =$ "excelente película"

Positivo

Decisión final:

$$\frac{3}{169} > \frac{3}{242}$$

Practiquemos lo visto hasta ahora

Link al Colab

LINK

Desafio

Link al Colab

LINK

NLP Clásico vs NLP + DL vs LLMs

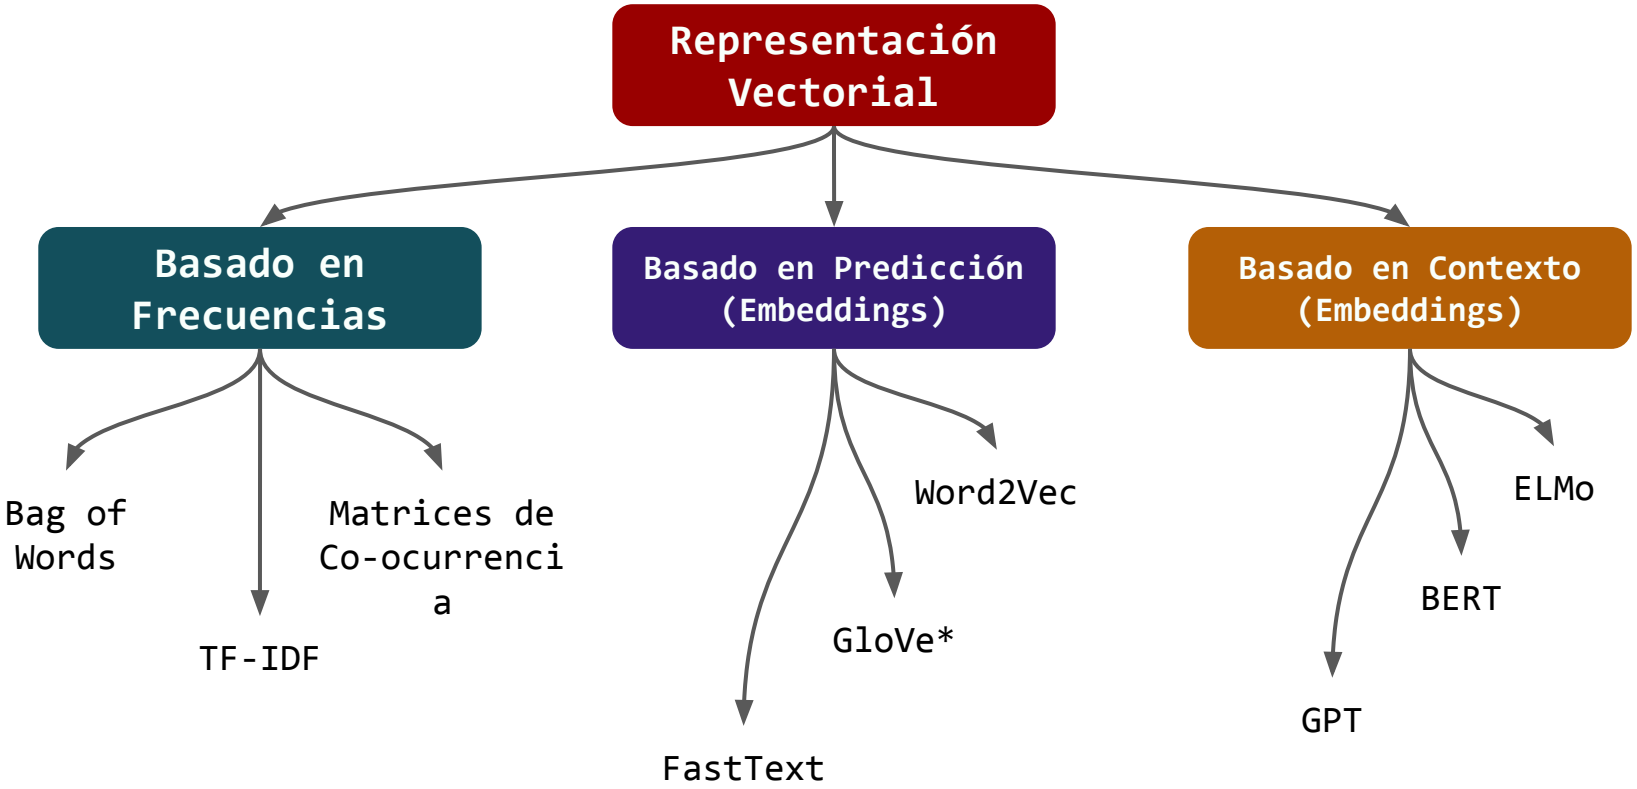

NLP Clásico vs NLP + DL vs LLMs

NLP Clásico

1.- Texto
2.- Tokenización
3.- Stop words removal
4.- Stemming / Lemmatization
5.- Vectorización (BoW, TF-IDF)
6.- Modelo ML

NLP + DL

1.- Texto
2.- Tokenización
3.- Subword tokenization (BPE, WordPiece)
4.- Embeddings
5.- Modelo

LLMs

1.- Texto
2.- Tokenizer (BPE / WordPiece / SentencePiece)
3.- IDs de tokens
4.- Transformer

Sobre el uso de LLMs y asistentes de código en la materia…

¡¡Totalmente permitidos!!

Especificar modelo/asistente usado, fecha y prompts utilizados.

Recuerden que los LLM son asistentes para su trabajo y no un reemplazo de su trabajo.